

Introduction to Bioinformatics with Offord Nanopore Sequencing

Van Lam Nguyen


Bioinformatic Research Scientist
Department of Computational Biology
St. Jude Children's Research Hospital
Memphis, TN, USA

Mục tiêu chung

- Khoá học này được thiết kế cho các bạn có nền tảng về sinh học và bắt đầu làm quen với Tin sinh học.
- Tập trung vào dữ liệu ONT sequencing, với workflow cơ bản.
 - Đánh giá chất lượng (Quality control)
 - Ánh xạ vào hệ gen tham chiếu (Alignment)
 - Xác định variant (Variant calling)
 - Chú giải (Annotation)

Bioinformatics là gì?


- **Bioinformatics** là một lĩnh vực liên ngành, kết hợp sinh học, khoa học máy tính và thống kê để thu thập, xử lý, phân tích và diễn giải dữ liệu sinh học.
- Bioinformatics đóng vai trò như cầu nối giữa **Sinh học** và **công nghệ**, giúp biến dữ liệu sinh học phức tạp thành thông tin có thể hiểu và sử dụng được.



Tại sao Bioinformatics?


- Bioinformatics giúp chuyển dữ liệu (giải trình tự) thành thông tin sinh học.
- Ví dụ:
 - Dữ liệu giải trình tự có đạt chất lượng không?
 - Mẫu này có variant nào không?
 - Variant đó nằm ở gene nào?
 - Variant đó có tin cậy không?
 - Tác động của variant đó là gì?
 -

Từ mẫu thực nghiệm đến tin sinh học




Khái niệm cơ bản

Variant calling workflow



Genome, reference genome, read

- **Genome:** Toàn bộ thông tin di truyền của sinh vật.
- **Reference genome:** Hệ gen được dùng để tham chiếu, so sánh.
- **Read:** Dữ liệu giải trình tự, thường là FastQ



FASTQ

Header

Sequence

Quality

```
@HWI-ST227:389:C4WA2ACXX:7:1204:2272:59979
GGAGGAAGGTCCTCGCTCCTCTTTCATATAAGGGAAATGGCTGAAT
+
FFFFHHHHHHHJIIJJJJJJJJIIJJJIGIGIGGIJJIIJIIJJJJJJIII
@HWI-ST227:389:C4WA2ACXX:7:1205:15214:42893
GAGGATCCCAGGGAGGAAGGTCCTCGCTCCTCTTTCATCTAAGGGA
+
12BAFB?A:3<AE1@<FF;1*@(EG*)?0?DBD>9BF9B*?#####
@HWI-ST227:389:C4WA2ACXX:8:2208:2467:44624
AAAGAGGAGAGAGGACCATCCTCCCTGGGATCCTCAGAAGTCTACT
+
BDDA:DB?2AA@FC>F?EEGC<FED>GFD;?GBB?<?F99*/9?9?
```

Phred quality score là thang điểm dùng để biểu diễn độ tin cậy của một base được gọi sau bước **basecalling**.

Phred quality score: $Q = -10 \log_{10} P$

Base error probability: $P = 10^{\frac{-Q}{10}}$

Phred score	Cách tính	Xác suất sai	Độ chính xác xấp xỉ
Q10	$10^{(-10/10)} = 10^{-1}$	0.1 = 10%	90%
Q20	$10^{(-20/10)} = 10^{-2}$	0.01 = 1%	99%
Q30	$10^{(-30/10)} = 10^{-3}$	0.001 = 0.1%	99.9%

FASTQ

Phred score được biểu diễn như thế nào trong FastQ?

Header Sequence Quality

```
@HWI-ST227:389:C4WA2ACXX:7:1204:2272:59979
GGAGGAAGGTCCTCGCTCCTCTTTCATATAAGGGAATGGCTGAAT
+
FFFFHHHHHHJIIJJJJJJJJIIJJIGIGIGGIJJIIJJJJJJIIII
@HWI-ST227:389:C4WA2ACXX:7:1205:15214:42893
GAGGATCCCAGGGAGGAAGGTCCTCGCTCCTCTTTCATCTAAGGGA
+
12BAFB?A:3<AE1@<FF;1*@(EG*)?0?DBD>9BF9B*?#####
@HWI-ST227:389:C4WA2ACXX:8:2208:2467:44624
AAAGAGGAGAGAGGACCATCCTCCCTGGGATCCTCAGAAGTCTACT
+
BDDA:DB?2AA@FC>F?EEGC<FED>GFD;?GBB?<?F99*/9?9?
```

Phred quality score là thang điểm dùng để biểu diễn độ tin cậy của một base được gọi sau bước **basecalling**.

Phred quality score: $Q = -10 \log_{10} P$

Base error probability: $P = 10^{-\frac{Q}{10}}$

ASCII Table

Dec	Chr	Dec	Chr	Dec	Chr	Dec	Chr	Dec	Chr
0	NUL	26	SUB	52	4	78	N	104	h
1	SOH	27	ESC	53	5	79	O	105	i
2	STX	28	FS	54	6	80	P	106	j
3	ETX	29	GS	55	7	81	Q	107	k
4	EOT	30	RS	56	8	82	R	108	l
5	ENQ	31	US	57	9	83	S	109	m
6	ACK	32		58	:	84	T	110	n
7	BEL	33	!	59	;	85	U	111	o
8	BS	34	"	60	<	86	V	112	p
9	HT	35	#	61	=	87	W	113	q
10	LF	36	\$	62	>	88	X	114	r
11	VT	37	%	63	?	89	Y	115	s
12	FF	38	&	64	@	90	Z	116	t
13	CR	39	'	65	A	91	[	117	u
14	SO	40	(	66	B	92	\	118	v
15	SI	41	)	67	C	93	]	119	w
16	DLE	42	*	68	D	94	^	120	x
17	DC1	43	+	69	E	95			
18	DC2	44	,	70	F	96			
19	DC3	45	-	71	G	97			
20	DC4	46	.	72	H	98			
21	NAK	47	/	73	I	99			
22	SYN	48	0	74	J	100			
23	ETB	49	1	75	K	101	e	121	y
24	CAN	50	2	76	L	102	f		
25	EM	51	3	77	M	103	g		

- **Phred+33 (hiện tại)**
 - Phred score + 33
 - ONT
 - Illumina
- **Phred+64 (cũ hơn)**
 - Phred score +64

Phred Score	Phred+33 Encoding (ASCII)	ASCII Character	Phred+64 Encoding (ASCII)	ASCII Character
30	30 + 33 = 63	'?'	30 + 64 = 94	'^'
40	40 + 33 = 73	'I'	40 + 64 = 104	'h'

<https://www.asciitable.com/>

FASTA


- FASTA là cấu trúc dữ liệu chỉ chứa trình tự, không có quality.
- Gồm 2 phần chính
 - Dòng mô tả: luôn bắt đầu từ ký tự “>”
 - Tiếp sau đó là trình tự: Nucleotide, amino acid
- Ví dụ
 >chr1
 ACGTACGTACGTACGTACGT
- Dùng cho:
 - Reference genome
 - Gene/protein sequence

SAM - BAM

SAM: Sequence Alignment Map

- Cấu trúc quan trọng chứa thông tin mapping của reads với hệ gen tham chiếu.
- Bao gồm 11 trường thông tin bắt buộc

BAM: Binary Alignment Map: Là file nén của SAM



SAM - BAM

Thứ tự	Field	Ý nghĩa	Ví dụ
1	QNAME	Tên read / query name	QNAME = read_001
2	FLAG	Mã số mô tả trạng thái alignment của read	FLAG = 0
3	RNAME	Tên reference/chromosome nơi read map vào	RNAME = chr1
4	POS	Vị trí bắt đầu alignment trên reference, 1-based	POS = 10001
5	MAPQ	Mapping quality	MAPQ = 60
6	CIGAR	Cách read align với reference	CIGAR = 100M
7	RNEXT	Reference/chromosome của mate read	RNEXT = *
8	PNEXT	Vị trí của mate read	PNEXT = 0
9	TLEN	Template length / insert size	TLEN = 0
10	SEQ	Sequence của read	SEQ = ACGTACGT...
11	QUAL	Base quality string	QUAL = IIIIIIII...

SAM FLAG

Bit		Description
1	0x1	template having multiple segments in sequencing
2	0x2	each segment properly aligned according to the aligner
4	0x4	segment unmapped
8	0x8	next segment in the template unmapped
16	0x10	SEQ being reverse complemented
32	0x20	SEQ of the next segment in the template being reverse complemented
64	0x40	the first segment in the template
128	0x80	the last segment in the template
256	0x100	secondary alignment
512	0x200	not passing filters, such as platform/vendor quality controls
1024	0x400	PCR or optical duplicate
2048	0x800	supplementary alignment

SAM CIGAR

CIGAR	Chú giải
M	Base của read được align với reference, nhưng có thể là match hoặc mismatch .
I	Insertion : có base trong read nhưng không có base tương ứng trên reference.
D	Deletion : có base trên reference nhưng read bị thiếu base đó.
N	Skipped region : bỏ qua một đoạn dài trên reference, thường gặp trong RNA-seq/splicing.
S	Soft clipping : base vẫn có trong read sequence nhưng không được align vào reference.
H	Hard clipping : base bị loại khỏi read sequence trong SAM/BAM, không còn thấy trong cột SEQ.
P	Padding : ký hiệu đệm trong multiple alignment, rất ít gặp trong phân tích thông thường.
=	Exact match : base của read giống chính xác với base trên reference.
X	Mismatch : base của read khác với base trên reference.

50M5I45M

- 50 bases align,
- 5 bases insertion trong read,
- 45 bases align tiếp.

VCF – Variant Calling Format

```
##fileformat=VCFv4.2
##fileDate=20090805
##source=myImputationProgramV3.1
##reference=file:///seq/references/1000GenomesPilot-NCBI36.fasta
##contig=<ID=20,length=62435964,assembly=B36,md5=f126cdf8a6e0c7f379d618ff66beb2da,species="Homo sapiens",taxonomy=x>
##phasing=partial
##INFO=<ID=NS,Number=1,Type=Integer,Description="Number of Samples With Data">
##INFO=<ID=DP,Number=1,Type=Integer,Description="Total Depth">
##INFO=<ID=AF,Number=A,Type=Float,Description="Allele Frequency">
...
20 14370 rs6054257 G A 29 PASS NS=3;DP=14;AF=0.5;DB;H2 GT:GQ:DP:HQ 0|0:48:1:51,51 1|0:48:8:51,51 1/1:43:5:.,.
20 17330 . T A 3 q10 NS=3;DP=11;AF=0.017 GT:GQ:DP:HQ 0|0:49:3:58,50 0|1:3:5:65,3 0/0:41:3
20 1110696 rs6040355 A G,T 67 PASS NS=2;DP=10;AF=0.333,0.667;AA=T;DB GT:GQ:DP:HQ 1|2:21:6:23,27 2|1:2:0:18,2 2/2:35:4
20 1230237 . T . 47 PASS NS=3;DP=13;AA=T GT:GQ:DP:HQ 0|0:54:7:56,60 0|0:48:4:51,51 0/0:61:2
20 1234567 microsat1 GTC G,GTCT 50 PASS NS=3;DP=9;AA=G GT:GQ:DP 0/1:35:4 0/2:17:2 1/1:40:3
```


Practice

Practice command lines

Công cụ: Terminal

Navigation

<code>pwd</code>	<code># xem thư mục hiện tại</code>
<code>ls</code>	<code># liệt kê file/folder</code>
<code>ls -lh</code>	<code># liệt kê kèm size dễ đọc</code>
<code>cd folder_name</code>	<code># đi vào thư mục</code>
<code>cd ..</code>	<code># quay lại thư mục cha</code>
<code>mkdir folder_name</code>	<code># tạo thư mục mới</code>
<code>cp file1 file2</code>	<code># copy file</code>
<code>cp -r dir1 dir2</code>	<code># copy thư mục</code>
<code>mv old new</code>	<code># đổi tên hoặc di chuyển file</code>
<code>rm file</code>	<code># xóa file</code>
<code>rm -r folder</code>	<code># xóa thư mục</code>

Practice command lines

Working with file

```
head file.txt      # xem vài dòng đầu
tail file.txt      # xem vài dòng cuối
less file.txt      # xem file dài
cat file.txt       # in toàn bộ nội dung file
wc -l file.txt     # đếm số dòng
grep "text" file   # tìm dòng chứa text
```

Gzip file

```
zcat reads.fastq.gz | head    # xem file .gz
gunzip file.gz                # giải nén .gz
tar -xzvf file.tar.gz         # giải nén tar.gz
unzip file.zip                 # giải nén zip
```

Working with sever

```
scp file user@server:/path/    # upload file lên server
scp user@server:/path/file .   # download file về laptop
rsync -avh --progress dir/ user@server:/path/dir/
```

Demo Login to sever

```
ssh ont_bio@3.20.225.243
```

Password: ont2026


```
> ssh ont_bio@3.20.225.243
ont_bio@3.20.225.243's password:
_#_
~\ _####_ Amazon Linux 2023
~\ _#####\
~\ _###|
~\ _#/_____ https://aws.amazon.com/linux/amazon-linux-2023
~\ _V~' ' ->
~\ _/
~\ _/
~\ _/
~\ _/m/'
Last login: Wed Sep 2 02:19:20 2026 from 73.252.77.149
```

Transfer file between local <-> sever using Filezilla

Công cụ: Filezilla

#installation

```
sudo apt install filezilla
```



Conda environment

Công cụ: Anaconda

#installation

```
mkdir -p ~/miniconda3
```

```
wget https://repo.anaconda.com/miniconda/Miniconda3-latest-Linux-x86\_64.sh -O ~/miniconda3/miniconda.sh
```

create environment

```
conda env create -f ont.yml
```

```
name: ont
```

```
channels:
```

- conda-forge
- bioconda
- defaults

```
dependencies:
```

- python=3.10
- wget
- curl
- unzip
- gzip
- tree
- seqkit
- nanoplot
- minimap2
- samtools
- bcftools
- htlib
- tabix

Practice with Samtools

View first alignments

```
samtools view 03_bam/DEMO.subset.bam | head
```

View BAM with header

```
samtools view -h 03_bam/DEMO.subset.bam | head -n 30
```

View header only

```
samtools view -H 03_bam/DEMO.subset.bam
```

Count alignments

```
samtools view -c 03_bam/DEMO.subset.bam
```

Mapping summary

```
samtools flagstat 03_bam/DEMO.subset.bam
```

Summary

- Bioinformatics là gì?
- Các bước chính trong variant calling.
- Khái niệm và cấu trúc dữ liệu nền tảng.
- Các login và giao tiếp với sever
- Làm quen với môi trường command line (unix)
- Setup môi trường làm việc sử dụng anaconda.