

Introduction to Bioinformatics with Oxford Nanopore Sequencing

Van Lam Nguyen

Bioinformatics Research Scientist
Department of Computational Biology
St. Jude Children's Research Hospital
Memphis, TN, USA

Mục tiêu chung của khóa học

Sau khóa học, học viên có thể theo dõi dữ liệu ONT từ raw signal đến variant annotation.

- | | | |
|----|-------------------|--|
| 01 | Hiểu workflow | POD5 → FASTQ → QC → alignment → variant → annotation |
| 02 | Đọc dữ liệu | Nhận biết và kiểm tra các file FASTA, FASTQ, BAM, VCF và BED |
| 03 | Đánh giá kết quả | Đọc QC report, xem alignment và nhận biết variant calls |
| 04 | Thực hành độc lập | Sử dụng command line, server và môi trường Conda |

Mục tiêu Buổi 1

Mô tả được vai trò của bioinformatics trong quy trình giải trình tự.

Phân biệt genome, reference genome, read, variant và coverage.

Nhận biết FASTA, FASTQ, SAM/BAM, VCF và BED.

Thực hiện các lệnh Unix cơ bản và truy cập server an toàn.

Tạo và kích hoạt môi trường Conda từ file YAML.

Chuẩn bị phần mềm trước phần thực hành

Terminal / WSL2

Chạy command line

`pwd` hoặc `wsl --status`

FileZilla Client

Truyền file qua SFTP

Mở ứng dụng và chọn SFTP

Conda

Quản lý môi trường

`conda --version`

IGV Desktop

Xem BAM và VCF


Mở IGV và chọn genome

Nếu chưa cài được, học viên vẫn có thể sử dụng output được chuẩn bị sẵn.

Bioinformatics là gì?

Bioinformatics là lĩnh vực liên ngành kết hợp sinh học, khoa học máy tính và thống kê để thu thập, xử lý, phân tích và diễn giải dữ liệu sinh học.

Đóng vai trò như cầu nối giữa **Sinh học** và **công nghệ**, giúp biến dữ liệu sinh học phức tạp thành thông tin có thể hiểu và sử dụng được.



Tại sao cần bioinformatics?

Bioinformatics biến dữ liệu giải trình tự thành thông tin có thể kiểm tra và diễn giải.

Dữ liệu giải trình tự có đạt chất lượng không?


Read được ánh xạ tới vị trí nào trên reference genome?

Mẫu có variant nào và variant đó có đáng tin cậy không?

Variant nằm trong gene/vùng chức năng nào?

Bằng chứng hiện có nói gì về tác động của variant?


Từ mẫu thực nghiệm đến kết quả sinh học



PHẦN 1

Các khái niệm và định dạng file cơ bản

Variant calling




Genome, reference genome và read

Genome: toàn bộ vật liệu di truyền của một sinh vật.

Reference genome: trình tự đại diện dùng làm hệ tọa độ để so sánh và báo cáo kết quả.

Read: chuỗi nucleotide được máy giải trình tự ghi nhận; sau basecalling thường được lưu trong FASTQ.

ONT tạo long reads: mỗi read có thể dài từ hàng nghìn đến hàng chục nghìn base hoặc hơn.



FASTQ

Header

Sequence

Quality

```
@HWI-ST227:389:C4WA2ACXX:7:1204:2272:59979
GGAGGAAGGTCCTCGCTCCTCTTTCATATAAGGGAAATGGCTGAAT
+
FFFFHHHHHHJIIJJJJJJJJIIJJIGIGIGGIJJIIJJJJJJIIII
@HWI-ST227:389:C4WA2ACXX:7:1205:15214:42893
GAGGATCCCAGGGAGGAAGGTCCTCGCTCCTCTTTCATCTAAGGGA
+
12BAFB?A:3<AE1@<FF;1* @EG*) ?0?DBD>9BF9B*?#####
@HWI-ST227:389:C4WA2ACXX:8:2208:2467:44624
AAAGAGGAGAGAGGACCATCCTCCCTGGGATCCTCAGAAGTCTACT
+
BDDA:DB?2AA@FC>F?EEGC<FED>GFD;?GBB?<?F99*/9?9?
```

Phred quality score là thang điểm dùng để biểu diễn độ tin cậy của một base được gọi sau bước **basecalling**.

Phred quality score: $Q = -10 \log_{10} P$

Base error probability: $P = 10^{\frac{-Q}{10}}$

Phred score	Cách tính	Xác suất sai	Độ chính xác xấp xỉ
Q10	$10^{(-10/10)} = 10^{-1}$	0.1 = 10%	90%
Q20	$10^{(-20/10)} = 10^{-2}$	0.01 = 1%	99%
Q30	$10^{(-30/10)} = 10^{-3}$	0.001 = 0.1%	99.9%

Phred Score: Độ tin cậy của basecalling

Quality

```
@HWI-ST227:389:C4WA2ACXX:7:1204:2272:59979
GGAGGAAGGTCCTCGCTCCTCTTTCATATAAGGGAAATGGCTGAAT
+
FFFFHHHHHHHJIIJJJJJJJIIJJJIGIGIGGIJJIIJIIJJJJJIIII
@HWI-ST227:389:C4WA2ACXX:7:1205:15214:42893
GAGGATCCCAGGGAGGAAGGTCCTCGCTCCTCTTTCATCTAAGGGA
+
12BAFB?A:3<AE1@<FF;1*(EG*)?0?DBD>9BF9B*?#####
@HWI-ST227:389:C4WA2ACXX:8:2208:2467:44624
AAAGAGGAGAGAGGACCATCCTCCCTGGGATCCTCAGAAGTCTACT
+
BDDA:DB?2AA@FC>F?EEGC<FED>GFD;?GBB?<?F99*/9?9?
```

Phred quality score là thang điểm dùng để biểu diễn độ tin cậy của một base được gọi sau bước **basecalling**.

Phred quality score: $Q = -10 \log_{10} P$

Base error probability: $P = 10^{\frac{-Q}{10}}$

ASCII Table

Dec	Chr	Dec	Chr	Dec	Chr	Dec	Chr	Dec	Chr
0	NUL	26	SUB	52	4	78	N	104	h
1	SOH	27	ESC	53	5	79	O	105	i
2	STX	28	FS	54	6	80	P	106	j
3	ETX	29	GS	55	7	81	Q	107	k
4	EOT	30	RS	56	8	82	R	108	l
5	ENQ	31	US	57	9	83	S	109	m
6	ACK	32		58	:	84	T	110	n
7	BEL	33	!	59	;	85	U	111	o
8	BS	34	"	60	<	86	V	112	p
9	HT	35	#	61	=	87	W	113	q
10	LF	36	\$	62	>	88	X	114	r
11	VT	37	%	63	?	89	Y	115	s
12	FF	38	&	64	@	90	Z	116	t
13	CR	39	'	65	A	91	[	117	u
14	SO	40	(	66	B	92	\	118	v
15	SI	41	)	67	C	93	]	119	w
16	DLE	42	*	68	D	94	^	120	x
17	DC1	43	+	69	E	95		Phred Score 30 40	
18	DC2	44	,	70	F	96			
19	DC3	45	-	71	G	97			
20	DC4	46	.	72	H	98			
21	NAK	47	/	73	I	99			
22	SYN	48	0	74	J	100			
23	ETB	49	1	75	K	101	e	121	DEL
24	CAN	50	2	76	L	102	f		
25	EM	51	3	77	M	103	g		

- **Phred+33 (hiện tại)**
 - **Phred score + 33**
 - **ONT**
 - **Illumina**
- **Phred+64 (cũ hơn)**
 - **Phred score +64**

Phred Score	Phred+33 Encoding (ASCII)	ASCII Character	Phred+64 Encoding (ASCII)	ASCII Character
30	$30 + 33 = 63$	'?'	$30 + 64 = 94$	'^'
40	$40 + 33 = 73$	'I'	$40 + 64 = 104$	'h'

<https://www.asciitable.com/>

FASTA chỉ lưu trình tự

```
>chr20_demo_region  
ACGTACGTACGTACGTACGT
```

Dòng header bắt đầu bằng ký tự >

Các dòng tiếp theo chứa trình tự nucleotide hoặc protein

Không lưu base quality

Thường dùng cho reference genome, gene hoặc protein sequence

SAM và BAM lưu kết quả alignment


SAM — Sequence Alignment/Map format: dạng text, dễ đọc nhưng dung lượng lớn.

BAM — dạng nhị phân của SAM: gọn hơn và xử lý nhanh hơn.

Mỗi record mô tả một alignment của read lên reference genome (11 trường thông tin bắt buộc)

BAM đã sắp xếp thường đi kèm file index .bai để truy cập nhanh theo vùng.

Chi tiết alignment sẽ được học ở Buổi 4.



Variant là gì?

Variant là sự khác biệt giữa trình tự của mẫu và reference genome được sử dụng để so sánh.

SNV: thay đổi một nucleotide


Insertion/Deletion (indel): thêm hoặc mất một đoạn ngắn

Structural variant (SV): thay đổi cấu trúc lớn

Copy-number variant (CNV): thay đổi số lượng bản sao

Variant không đồng nghĩa với biến thể gây bệnh; cần annotation và interpretation.

Depth Coverage and Breadth Coverage



BED: Browser Extensible Data

```
chr20 100000 101000 demo_region
```

- Cột 1: chromosome
- Cột 2: start — thường là 0-based
- Cột 3: end — không bao gồm vị trí end (half-open)
- Cột 4: tên vùng, không bắt buộc
- BED dùng để mô tả exon, gene, target region hoặc vùng cần phân tích.

VCF lưu các variant được phát hiện

```
#CHROM POS ID REF ALT QUAL FILTER INFO
chr20 10001 . A G 45 PASS DP=32
```

CHROM/POS: chromosome và vị trí 1-based

REF/ALT: allele tham chiếu và allele quan sát được

QUAL/FILTER: độ tin cậy và trạng thái lọc của variant call

INFO: các thuộc tính bổ sung, ví dụ DP là depth

Tóm tắt định dạng file chính

Định dạng	Nội dung chính	Phân mở rộng thường gặp
FASTA	Reference hoặc sequence	.fa, .fasta, .fa.gz
FASTQ	Read và base quality	.fastq, .fastq.gz
SAM/BAM	Alignment của read	.sam, .bam (+ .bai)
VCF	Variant calls	.vcf, .vcf.gz (+ .tbi)
BED	Khoảng tọa độ trên genome	.bed

PHẦN 2

Thực hành: command line và môi trường làm việc

Thực hành: điều hướng và quản lý thư mục

```
pwd
ls -lh
cd 01_fastq
cd ..
mkdir results
cp file1.txt results/
mv old.txt new.txt
```

pwd — in đường dẫn thư mục hiện tại

ls -lh — -l: chi tiết; -h: kích thước dễ đọc

cd — chuyển thư mục; .. là thư mục cha

mkdir — tạo thư mục mới

cp — sao chép; mv — di chuyển hoặc đổi tên

Cẩn thận với rm: file bị xóa trong terminal thường không vào Recycle Bin/Trash.

Thực hành: xem nội dung file

```
head -n 8 01_fastq/demo.fastq
less 02_reference/demo.fa
wc -l 05_bed/regions.bed
grep '^>' 02_reference/demo.fa
zcat 01_fastq/demo.fastq.gz | head
```

-n 8: chỉ in 8 dòng đầu

less: xem file dài; nhấn q để thoát


wc -l: đếm số dòng

grep '^>': tìm các header FASTA

|: chuyển output của lệnh trái sang lệnh phải

zcat đọc file .gz mà không cần giải nén ra đĩa.

Laptop, server và HPC



Đăng nhập server bằng SSH

```
ssh <username>@<server-address>
```

```
ssh ont bio@3.20.225.243
```

```
Password: ont2026
```

ssh — chương trình kết nối từ xa an toàn

<username> — tài khoản được cấp trên server

<server-address> — hostname hoặc địa chỉ IP

Nhập password khi được hỏi; ký tự sẽ không hiện trên màn hình

Cài đặt FileZilla Client

Windows

Tải FileZilla Client từ trang chính thức
filezilla-project.org/download.php?type=client

macOS (Homebrew)

```
brew install --cask filezilla
```

Ubuntu / Debian

```
sudo apt update  
sudo apt install filezilla
```

Sau khi cài: mở FileZilla Client → Site Manager → chọn protocol SFTP và port 22.

Truyền file giữa laptop và server bằng FileZilla

Protocol: SFTP — SSH File Transfer Protocol

Host: <server-address>

Username: <username>

Port: 22

Kéo–thả file giữa cửa sổ Local site và Remote site

Không đưa password hoặc SSH private key lên slide, GitHub hay thư mục dùng chung.

Cài Conda

```
#installation
cd /tmp
wget https://repo.anaconda.com/miniconda/Miniconda3-latest-Linux-x86\_64.sh
bash Miniconda3-latest-Linux-x86_64.sh
#follow instruction
```

```
name: ont
channels:
  - conda-forge
  - bioconda
  - defaults
```

```
dependencies:
  - python=3.11
  - wget
  - curl
  - unzip
  - gzip
  - tree
  - seqkit
  - nanoplot
  - minimap2
  - samtools
  - bcftools
  - htslib
  - tabix
```

Tạo môi trường Conda cho khóa học

```
# Tạo môi trường từ file YAML
conda env create -f ont.yml

# Kích hoạt môi trường
conda activate ont

# Kiểm tra
conda env list
which samtools
samtools --version
```

conda env create: tạo môi trường mới

-f ont.yml: đọc cấu hình từ file ont.yml

conda activate ont: chuyển sang môi trường ont

which: cho biết chương trình đang được gọi từ đâu

--version: xác nhận phần mềm chạy được

Bài thực hành 1: khám phá bộ dữ liệu demo

```
pwd
ls -lh
tree -L 2
head -n 4 01_fastq/demo.fastq
grep '^>' 02_reference/demo.fa
wc -l 05_bed/regions.bed
```

Xác định thư mục hiện tại.

Nhận biết năm loại file của khóa học.

Kiểm tra một FASTQ record có đủ bốn dòng.

Tìm header của reference FASTA.

Đếm số vùng trong BED.

Kết quả: mỗi nhóm ghi lại tên file, định dạng và vai trò của file.

Bài thực hành 2: đọc lệnh theo từng thành phần

```
zcat 01_fastq/demo.fastq.gz | head -n 8
```

zcat — đọc và giải nén luồng dữ liệu từ file .gz

01_fastq/demo.fastq.gz — đường dẫn đến file đầu vào

| — pipe output sang lệnh kế tiếp

head — chỉ lấy phần đầu của dữ liệu

-n 8 — in chính xác 8 dòng, tương ứng hai FASTQ records

Câu hỏi: nếu dùng head -n 10, output có kết thúc đúng ranh giới FASTQ record không?

Tổng kết Buổi 1

Bioinformatics kết nối dữ liệu sequencing với câu hỏi sinh học.

Genome, reference, read, variant và coverage là các khái niệm nền tảng.

FASTA, FASTQ, SAM/BAM, VCF và BED có vai trò khác nhau trong workflow.

Laptop, server và HPC được sử dụng cho các quy mô phân tích khác nhau.

Command line và Conda giúp tạo môi trường phân tích có thể tái lập.