

Introduction to Bioinformatics with Oxford Nanopore Sequencing

Van Lam Nguyen

Bioinformatics Research Scientist
Department of Computational Biology
St. Jude Children's Research Hospital
Memphis, TN, USA

Nội dung buổi 3

Kiểm tra FASTQ vừa tạo buổi 2

Giải thích read count, yield, median, N50 và Q-score.

Đánh giá chất lượng sử dụng Fastqc, seqkit, và Nanoplot.

Đọc hiểu các báo cáo

Demo cleaning dữ liệu và so sánh

Quy trình tổng quát



Kiểm tra file fastq

```
cd ONT_practice #vào thư mục project hôm trước
pwd
find data -type f | sort

#kiểm tra file nén có lỗi gì không?
gzip -t data/fastq/HG002.chr20.fastq.gz

#kiểm tra status của câu lệnh trước đó
echo $?
```

Activate môi trường

```
conda activate ont
```

```
fastqc --version # nếu chưa có thì cài: conda install fastqc
```

```
NanoPlot -version
```

PHẦN 1

QC report cần trả lời điều gì?

FASTQ QC trả lời một số câu hỏi quan trọng!

Có bao nhiêu reads?

Tổng yield là bao nhiêu bases?

Chiều dài reads phân bố như thế nào?

Basecaller dự đoán chất lượng reads như thế nào?

FASTQ có đạt chất lượng để chuyển sang bước tiếp theo hay không?

Mean, median và quartiles

Mean: tổng chiều dài / số reads; nhạy với một vài read rất dài.

Median (Q2): 50% reads ngắn hơn và 50% reads dài hơn.

Q1 và Q3 mô tả phần giữa của phân bố.

Báo cả mean và median để thấy ảnh hưởng của long tail.

N50: tính theo tổng số bases

Ví dụ chiều dài: 10 kb, 8 kb, 4 kb, 2 kb

Tổng = 24 kb | Mốc 50% = 12 kb

Cộng từ read dài nhất: $10 + 8 = 18 \text{ kb} \geq 12 \text{ kb}$

N50 = 8 kb

N50 là chiều dài L sao cho ít nhất 50% tổng số bases nằm trong các reads có chiều dài $\geq L$.

FASTQ QC chưa trả lời coverage

Alignment vẫn có thể chạy với một FASTQ nhỏ.

“Đủ dữ liệu” phụ thuộc genome/target size và mục tiêu phân tích.

Mapping rate, depth và coverage được đánh giá sau alignment ở buổi sau.

Q-score biểu diễn mức độ tin cậy của basecaller

$$Q = -10 \log_{10}(P_{\text{error}})$$

Phred quality score là thang điểm dùng để biểu diễn độ tin cậy của một base được gọi sau bước **basecalling**.

Phred score	Cách tính	Xác suất sai	Độ chính xác xấp xỉ	Ví dụ
Q10	$10^{(-10/10)} = 10^{-1}$	0.1 = 10%	90.00%	1 lần sai trong 10 lần gọi
Q20	$10^{(-20/10)} = 10^{-2}$	0.01 = 1%	99.00%	1 lần sai trong 100 lần gọi
Q30	$10^{(-30/10)} = 10^{-3}$	0.001 = 0.1%	99.90%	1 lần sai trong 1000 lần gọi
Q40	$10^{(-40/10)} = 10^{-4}$	0.0001 = 0.01%	99.99%	1 lần sai trong 10000 lần gọi

PHẦN 2

Thực hành Fastqc, SeqKit và NanoPlot

Fastqc

```
# vào thư mục chính ONT_practice  
  
mkdir results/01_qc/fastqc  
  
fastqc data/fastq/HG002.chr20.fastq.gz --memory 4096 -o results/01_qc/fastqc
```

```
🍏 > ~/Desktop/ONT/ONT_practice  
> fastqc data/fastq/HG002.chr20.fastq.gz --memory 4096 -o results/01_qc/fastqc  
application/gzip  
Started analysis of HG002.chr20.fastq.gz  
Approx 60% complete for HG002.chr20.fastq.gz  
Analysis complete for HG002.chr20.fastq.gz
```

Fastqc

```
# vào thư mục chính ONT_practice

mkdir results/01_qc/fastqc

fastqc data/fastq/HG002.chr20.fastq.gz --memory 4096 -o results/01_qc/fastqc
```

```
🍏 > ~ / Desktop / ONT / ONT_practice
> fastqc data/fastq/HG002.chr20.fastq.gz --memory 4096 -o results/01_qc/fastqc
application/gzip
Started analysis of HG002.chr20.fastq.gz
Approx 60% complete for HG002.chr20.fastq.gz
Analysis complete for HG002.chr20.fastq.gz
```

```
🍏 > ~ / Desktop / ONT / ONT_practice
> ls -lh results/01_qc/fastqc
total 2832
-rw-r--r--@ 1 lamnguyen  staff   805K Sep 16 11:20 HG002.chr20_fastqc.html
-rw-r--r--  1 lamnguyen  staff   607K Sep 16 11:20 HG002.chr20_fastqc.zip
```

Output

Fastqc: Note

Fastqc được thiết kế cho short-read sequencing

Một số thông số và plot không được tối ưu cho long-read sequencing

SeqKit: tạo bản thống kê cho file FASTQ

```
seqkit stats -a -T data/fastq/HG002.chr20.fastq.gz > results/01_qc/seqkit_stats.tsv
```

```
# -a: thống kê tất cả các thông số  
# -T: tạo ra dạng table.  
# >: lưu ra file tên là seqkit_stats.tsv
```

```
# View file
```

```
column -t results/01_qc/seqkit_stats.tsv
```

```
~/Desktop/ONT/ONT_practice  
> column -t results/01_qc/seqkit_stats.tsv  
file format type num_seqs sum_len min_len avg_len max_len Q1 Q2 Q3 sum_gap N50 N50_num Q20(%) Q30(%) AvgQual GC(%) sum_n  
data/fastq/HG002.chr20.fastq.gz FASTQ DNA 1727 29383851 165 17014.4 263186 820 11933 28070 0 30916 322 88 74 18.26 41.55 0
```


Các đọc kết quả seqkit stats

Cột	Ý nghĩa
file	Tên file đầu vào
format	Định dạng sequence
type	Loại trình tự, thường là DNA với ONT
num_seqs	Tổng số reads
sum_len	Tổng số bases của tất cả reads
min_len	Chiều dài read ngắn nhất
avg_len	Chiều dài read trung bình
max_len	Chiều dài read dài nhất
Q1	25% reads có length $\leq$ giá trị này
Q2	Median read length; 50% reads ngắn hơn hoặc bằng giá trị này
Q3	75% reads có length $\leq$ giá trị này
sum_gap	Tổng số ký tự gap như -, ., space; FASTQ thường bằng 0
N50	Length của read tại điểm các reads dài nhất đã đóng góp 50% tổng bases
N50_num	Số reads dài nhất cần để đạt 50% tổng bases
Q20(%)	% bases có Phred quality >20
Q30(%)	% bases có Phred quality >30
AvgQual	Quality trung bình của toàn bộ bases, tính thông qua error probability rồi chuyển lại thành Phred score
GC(%)	% bases là G hoặc C
sum_n	Tổng số ký tự ambiguous N/n/X/x

Tạo QC report với NanoPlot

```
NanoPlot --fastq data/fastq/HG002.chr20.fastq.gz \
--outdir results/01_qc/nanoplot \
--threads 4 \
--tsv_stats \
--title "HG002 chr20"
```

```
Apple > ~ / Desktop / ONT / ONT_practice / results / 01_qc / nanoplot
> ls -lh
total 2264
-rw-r--r--@ 1 lamnguyen staff 64K Sep 16 11:56 LengthvsQualityScatterPlot_dot.html
-rw-r--r--@ 1 lamnguyen staff 119K Sep 16 11:56 LengthvsQualityScatterPlot_dot.png
-rw-r--r--@ 1 lamnguyen staff 90K Sep 16 11:56 LengthvsQualityScatterPlot_kde.html
-rw-r--r--@ 1 lamnguyen staff 188K Sep 16 11:56 LengthvsQualityScatterPlot_kde.png
-rw-r--r--@ 1 lamnguyen staff 277K Sep 16 11:56 NanoPlot-report.html
-rw-r--r--@ 1 lamnguyen staff 15K Sep 16 11:56 NanoPlot_20260916_1156.log
-rw-r--r--@ 1 lamnguyen staff 737B Sep 16 11:56 NanoStats.txt
-rw-r--r--@ 1 lamnguyen staff 15K Sep 16 11:56 Non_weightedHistogramReadlength.html
-rw-r--r--@ 1 lamnguyen staff 37K Sep 16 11:56 Non_weightedHistogramReadlength.png
-rw-r--r--@ 1 lamnguyen staff 18K Sep 16 11:56 Non_weightedLogTransformed_HistogramReadlength.html
-rw-r--r--@ 1 lamnguyen staff 44K Sep 16 11:56 Non_weightedLogTransformed_HistogramReadlength.png
-rw-r--r--@ 1 lamnguyen staff 16K Sep 16 11:56 WeightedHistogramReadlength.html
-rw-r--r--@ 1 lamnguyen staff 45K Sep 16 11:56 WeightedHistogramReadlength.png
-rw-r--r--@ 1 lamnguyen staff 23K Sep 16 11:56 WeightedLogTransformed_HistogramReadlength.html
-rw-r--r--@ 1 lamnguyen staff 49K Sep 16 11:56 WeightedLogTransformed_HistogramReadlength.png
-rw-r--r--@ 1 lamnguyen staff 40K Sep 16 11:56 Yield_By_Length.html
-rw-r--r--@ 1 lamnguyen staff 53K Sep 16 11:56 Yield_By_Length.png
```

Summary statistics

Metrics	
number_of_reads	1727
number_of_bases	29383851.0
median_read_length	11933.0
mean_read_length	17014.4
read_length_stdev	18842.9
n50	30916.0
mean_qual	17.7
median_qual	20.5
longest_read_(with_Q):1	263186 (20.1)
longest_read_(with_Q):2	153722 (14.5)
longest_read_(with_Q):3	105738 (22.9)
longest_read_(with_Q):4	98282 (12.9)
longest_read_(with_Q):5	92009 (18.9)
highest_Q_read_(with_length):1	36.7 (355)
highest_Q_read_(with_length):2	35.9 (2011)
highest_Q_read_(with_length):3	34.7 (349)
highest_Q_read_(with_length):4	34.3 (527)
highest_Q_read_(with_length):5	34.1 (225)
Reads >Q10:	1721 (99.7%) 29.2Mb
Reads >Q15:	1524 (88.2%) 26.2Mb
Reads >Q20:	946 (54.8%) 16.9Mb
Reads >Q25:	119 (6.9%) 0.7Mb
Reads >Q30:	17 (1.0%) 0.0Mb

PHẦN 3

Trimming: Tinh sạch dữ liệu

Dorado Trimming

Đối với dữ liệu DNA, **--trim all** là mặc định trong basecaller:

- Primers
- Adapters
- Barcodes

```
dorado basecaller fast \  
  data/raw/pod5_demo/dorado_r10_demo.pod5 \  
  --trim all \  
  --emit-fastq
```

Lưu ý:

Dorado loại sequence kỹ thuật của thư viện ONT, không phải là một công cụ trimming tổng quát

Trimming with Chopper

Dorado

Nhận diện adapter/primer ONT

Thực hiện trong basecalling

Trimming bắt mặc định

Có thể lọc theo mean Q-score

Chopper

Trim base chất lượng thấp ở hai đầu

Xử lý FASTQ đã có

Người dùng phải chọn chiến lược

Lọc theo Q-score, length và GC

```
conda install chopper # install chopper

gunzip -c data/fastq/HG002.chr20.fastq.gz |
chopper \
  --trim-approach trim-by-quality --cutoff 10 --quality 10 \
  --minlength 1000 | gzip -c \
> data/fastq/HG002.chr20.trim_filter10.fastq.gz

# áp dụng với --quality 20
```

Tạo bảng so sánh với seqkit

```
seqkit stats -a -T \  
data/fastq/HG002.chr20.fastq.gz \  
data/fastq/HG002.chr20.trim_filterq10.fastq.gz \  
data/fastq/HG002.chr20.trim_filterq20.fastq.gz \  
> results/01_qc/trim_comparison.tsv
```

Tạo bảng so sánh với seqkit

Index	HG002.chr20.fast q.gz	trim_filterq10.f astq.gz	trim_filterq20.f astq.gz
num_seqs	1727	1246	700
sum_len	29383851	28967960	16798813
min_len	165	1000	1000
avg_len	17014.4	23248.8	23998.3
max_len	263186	262973	262973
Q1	820	7492	8866
Q2	11933	23168	24345
Q3	28070	31296	31886
sum_gap	0	0	0
N50	30916	31183	31326
N50_num	322	316	183
Q20(%)	88	88	94
Q30(%)	74	74	84
AvgQual	18.26	18.51	22.24
GC(%)	41.55	41.54	41.5

Một số câu hỏi?

1. Trimming làm mất bao nhiêu bases?
2. Filtering loại bao nhiêu reads?
3. Total yield giảm bao nhiêu phần trăm?
4. AvgQual tăng bao nhiêu?
5. N50 tăng vì dữ liệu tốt hơn hay vì các read ngắn đã bị loại?
6. Coverage downstream có thể bị ảnh hưởng như thế nào?

Bài tập luyện tập

1. Extract toàn bộ fastq read từ trong file demo.bam
2. Đánh giá chất lượng của file fastq vừa extract
3. Clean dữ liệu với sử dụng chopper với quality 10 và min length 500bp.
4. So sánh với file fastq ban đầu?