

BUỔI 5 — Variant Calling: Sử dụng Clair3

1. Nội dung chính

1. Phân biệt SNV, SNP, MNV, insertion, deletion, indel và structural variant.
 2. Phân biệt transition và transversion.
 3. Chọn model Clair3 phù hợp với chemistry và basecalling model.
 4. Chạy Clair3 trên dữ liệu ONT trong vùng đích (bed).
 5. Xác định file VCF kết quả cuối cùng của Clair3.
 6. Đọc các cột và trường thường gặp trong VCF.
 7. Phân biệt `QUAL`, `GQ`, `DP`, `AD`, `AF`, `FILTER` và `GT`.
 8. Chuẩn hóa, lọc và thống kê VCF bằng bcftools.
 9. Kiểm tra một số variant trên IGV
 10. So sánh Clair3 VCF với GIAB HG002 benchmark.
-

PHẦN 1 — CÁC LOẠI VARIANT

2. Variant là gì?

Một variant là vị trí hoặc đoạn trình tự của mẫu khác với reference genome được chọn.

Điều này không tự động có nghĩa rằng variant đó:

- gây bệnh
- hiếm
- nằm trong gene
- làm thay đổi protein
- hoặc là lỗi sequencing.

Để trả lời các câu hỏi trên cần thêm annotation, dữ liệu quần thể, cơ sở dữ liệu lâm sàng và đánh giá chất lượng. Buổi 5 tập trung vào **tìm kiếm variant**; annotation được thực hiện ở Buổi 6.

3. SNV và SNP

3.1 SNV — Single-Nucleotide Variant

Một nucleotide của mẫu khác với reference tại một vị trí.

Ví dụ:

```
Reference:  ... A C G T A ...
Sample:    ... A C A T A ...
              ↑
            G>A
```

Trong VCF:

```
REF = G
ALT = A
```

3.2 SNP — Single-Nucleotide Polymorphism

SNP thường được dùng cho một biến thể nucleotide đơn đã được quan sát như một polymorphism trong quần thể. Trong thực hành bioinformatics, SNP và SNV đôi khi được dùng thay nhau, nhưng cách dùng chính xác hơn là:

- **SNV**: mô tả loại thay đổi trong một mẫu.
- **SNP**: nhấn mạnh biến thể nucleotide đơn có tính polymorphism trong quần thể.

`bcftools view -v snps` sử dụng thuật ngữ kỹ thuật `snps` để chọn các record thay thế một nucleotide.

4. MNV/MNP — thay đổi nhiều nucleotide liền nhau

Ví dụ:

```
REF = GC
ALT = AT
```

Đây có thể được biểu diễn dưới dạng một MNV/MNP hoặc được tách thành các SNV lân cận, tùy caller và bước chuẩn hóa.

Không nên tự động giả định hai SNV sát nhau nằm trên cùng một haplotype. Thông tin phase và cách caller biểu diễn record phải được xem xét.

5. Insertion, deletion và indel

5.1 Insertion

Mẫu có thêm nucleotide so với reference.

Ví dụ khái niệm:

```
Reference:  A C - - G T
Sample:     A C T T G T
```

Trong VCF, insertion thường phải chứa một **base neo** chung ở bên trái:

```
REF = A
ALT = ATT
```

Độ dài insertion:

$$\text{length(ALT)} - \text{length(REF)} = 3 - 1 = 2 \text{ bp}$$

5.2 Deletion

Mẫu thiếu nucleotide so với reference.

Ví dụ VCF:

```
REF = ATC
ALT = A
```

Độ dài deletion:

$$\text{length(REF)} - \text{length(ALT)} = 3 - 1 = 2 \text{ bp}$$

5.3 Indel

Indel là cách gọi chung cho insertion và deletion nhỏ. Mốc khoảng 50 bp thường được dùng như một quy ước thực hành để phân biệt small indel với structural variant, nhưng đây không phải ranh giới sinh học tuyệt đối.

Clair3 tập trung vào small variants. Clair3 có tùy chọn hỗ trợ long indel, nhưng không nên dùng Clair3 thay thế cho một SV caller chuyên dụng khi mục tiêu là phát hiện deletion, insertion, inversion hoặc duplication lớn.

6. Multiallelic variant

Một vị trí có thể có nhiều hơn một ALT allele.

Ví dụ:

```
REF = A
ALT = C,G
```

Quy ước đánh số allele:

```
0 = REF = A
1 = ALT thứ nhất = C
2 = ALT thứ hai = G
```

Do đó:

```
GT = 1/2
```

7. Structural variant và CNV

Các loại thường gặp gồm:

- deletion lớn
- insertion lớn
- inversion
- duplication
- translocation
- copy-number variation.

Các biến thể này thường cần caller chuyên dụng như Sniffles2, cuteSV hoặc workflow SV tương đương; Chúng không phải là trọng tâm của khoá học này.

8. Transition và transversion

Các nucleotide được chia thành:

- **Purine:** A, G
- **Pyrimidine:** C, T

Transition

Thay đổi trong cùng nhóm:

A ↔ G
C ↔ T

Transversion

Thay đổi giữa hai nhóm:

A ↔ C
A ↔ T
G ↔ C
G ↔ T

So sánh trực tiếp

Thay đổi	Nhóm	Giải thích
G>A	Transition	Purine → purine
G>C	Transversion	Purine → pyrimidine

Toàn bộ 12 kiểu thay thế có hướng

REF>ALT	Phân loại	REF>ALT	Phân loại
A>G	Transition	G>A	Transition
C>T	Transition	T>C	Transition
A>C	Transversion	C>A	Transversion
A>T	Transversion	T>A	Transversion
C>G	Transversion	G>C	Transversion
G>T	Transversion	T>G	Transversion

9. Tại sao đôi khi G>A được gộp với C>T ?

Hai DNA strands bổ sung cho nhau:

G>A trên một strand
C>T trên strand bổ sung

Do đó, khi phân tích substitution spectrum không quan tâm strand, 12 phép thay thế có hướng thường được gộp thành 6 nhóm:

- C>A
- C>G
- C>T
- T>A
- T>C
- T>G

Tuy nhiên, trong VCF phải giữ nguyên REF>ALT đúng theo reference. Không tự ý đổi G>A thành C>T trong file VCF.

Chỉ từ ký hiệu G>A hoặc G>C chưa thể kết luận variant có gây bệnh hay làm thay đổi protein. Cần biết gene, transcript, codon và annotation.

10. Tỷ lệ transition/transversion – Ts/Tv

Ts/Tv = số transition / số transversion

Ts/Tv có thể hỗ trợ QC ở mức tập hợp biến thể, nhưng không có một ngưỡng duy nhất phù hợp cho mọi dataset.

Ts/Tv phụ thuộc vào:

- vùng whole genome, exome hay panel;
- vùng coding hay non-coding;
- cách lọc;
- ancestry và thiết kế dữ liệu;
- chất lượng gọi biến thể;
- cách xử lý multiallelic records.

Tỷ lệ Ts/Tv ở người thường khoảng:

- WGS: **2.0-2.1**
- WES/coding region thường cao hơn: **3.0-3.3**

Không nên dùng một giá trị Ts/Tv “chuẩn” của whole genome để kết luận trực tiếp cho một BED nhỏ trên chr20.


PHẦN 2 — VARIANT CALLING VỚI CLAIR3

11. Tổng quan Clair3

Clair3 kết hợp hai cách tiếp cận:

1. **Pileup model:** quét nhanh và gọi phần lớn vị trí.
2. **Full-alignment model:** xem xét chi tiết hơn các vị trí ứng viên khó.
3. **Merge:** hợp nhất kết quả thành VCF cuối cùng.

Indexed BAM + indexed reference + model phù hợp



Các file VCF chính

File	Ý nghĩa
pileup.vcf.gz	Kết quả của pileup model
full_alignment.vcf.gz	Kết quả của full-alignment model
merge_output.vcf.gz	Kết quả cuối cùng dùng cho phân tích tiếp theo

⚠ Không nối pileup.vcf.gz và full_alignment.vcf.gz thủ công. Sử dụng merge_output.vcf.gz là kết quả cuối cùng.

12. Chọn model Clair3 — Quan trọng!

Model phải phù hợp với:

- nền tảng ONT Sequencing
- pore/flow-cell chemistry
- sequencing speed
- basecalling model/generation
- phiên bản Clair3 đang dùng.

Ví dụ tên model có thể chứa các thành phần như:

r1041_e82_400bps_sup_...

Clair3 v1 và Clair3 v2

- Clair3 v1 sử dụng model TensorFlow.
- Clair3 v2 sử dụng model PyTorch.
- Model v1 và v2 không tương thích trực tiếp.

Dwell-time model

Một số model Clair3 v2 có cấu trúc liên quan `with_mv` và cần move-table tag `mv` từ Dorado cùng tùy chọn Clair3 tương ứng.

BAM của khóa học được tạo bằng cách align FASTQ với minimap2 nên không giữ move-table tag. Vì vậy buổi thực hành này dùng **model chuẩn không yêu cầu dwell time**.

13. Tạo environment Clair3 riêng

Không cài Clair3 vào environment `ont` đang dùng cho các công cụ cơ bản. Tách environment giúp giảm xung đột dependency.

```
In [111]: %%bash
#-----#
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont
#-----#

: <<'COMMENT'
conda create -n clair3 \
  -c conda-forge \
  -c bioconda \
  -y clair3=2.0.3 bcftools samtools bedtools
COMMENT
```

Kích hoạt môi trường

```
In [112]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"

conda activate clair3

which run_clair3.sh

/opt/miniconda3/envs/clair3/bin/run_clair3.sh
```

Kiểm tra các phần mềm cần thiết:

```
In [113]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
# conda activate ont

which run_clair3.sh
run_clair3.sh --help | head
bcftools --version | head -n 1
samtools --version | head -n 1

/Users/lamnguyen/Desktop/ONT/ONT_practice/tools/Clair3/run_clair3.sh
usage: run_clair3.py [-h] -b BAM_FN -f REF_FN -m MODEL_PATH -t THREADS -p
                    {ont,hifi,ilmn} -o OUTPUT [--bed_fn BED_FN]
                    [--vcf_fn VCF_FN] [--ctg_name CTG_NAME]
                    [--sample_name SAMPLE_NAME] [--qual QUAL]
                    [--samtools SAMTOOLS] [--python PYTHON_BIN] [--pypy PYPY]
                    [--parallel PARALLEL] [--whatshap WHATSHAP]
                    [--longphase LONGPHASE] [--chunk_num CHUNK_NUM]
                    [--chunk_size CHUNK_SIZE] [--snp_min_af SNP_MIN_AF]
                    [--indel_min_af INDEL_MIN_AF]
                    [--var_pct_full VAR_PCT_FULL]

bcftools 1.24
samtools 1.24
```

14. Kiểm tra basecaller model

- Cần nắm rõ thông tin này trong quá trình basecaller hoặc từ kit giải trình tự
- Nếu nhận data từ bên thứ 3 thì cần yêu cầu họ cung cấp thông tin

```
In [114]: %%bash

source "$(conda info --base)/etc/profile.d/conda.sh"
# conda activate ont

samtools view -H ./data/raw/wf_demo/wf-human-variation-demo/demo.bam | grep "base
call_model" | head -n 1

echo "basecall_model=dna_r10.4.1_e8.2_400bps_sup@v4.2.0"

@PG      ID:samtools.196 PN:samtools      PP:samtools.2   VN:1.19.2      CL:samto
ols addreplacerg -r @RG\tID:908efd0946d330670823fbb6b6780d79befc677e_dna_r10.4.1
_e8.2_400bps_sup@v4.2.0\tPU:PAU61426\tPM:PAPAP48\tDT:2024-01-17T16:43:32.933+00:
00\tPL:ONT\tDS:basecall_model=dna_r10.4.1_e8.2_400bps_sup@v4.2.0 modbase_models=
dna_r10.4.1_e8.2_400bps_sup@v4.2.0_5mCG_5hmCG@v3.1 runid=908efd0946d330670823fbb
6b6780d79befc677e\tLB:hg002\tSM:hg002 -@ 15 --write-index -O bam -o demo.bam##id
x##demo.bam.bai tmp.bam
basecall_model=dna_r10.4.1_e8.2_400bps_sup@v4.2.0
```

- Header có thể không lưu đầy đủ tên basecalling model. Khi đó phải sử dụng README/Metadata đi kèm dữ liệu; không suy đoán model chỉ từ sequence reads.
- Sau khi có thông tin model thì tải từ trang web của Clair3

Tải và kiểm tra model

[Link tải Clair3 Model \(https://www.bio8.cs.hku.hk/clair3/clair3_models_rerio_pytorch\)](https://www.bio8.cs.hku.hk/clair3/clair3_models_rerio_pytorch)

```
In [115]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"

rm -r config/clair3_models/r1041_e82_400bps_sup_v420

mkdir config/clair3_models/r1041_e82_400bps_sup_v420

# chỉ cần chạy 1 lần

wget -r -np -nd -l1 \
  -P config/clair3_models/r1041_e82_400bps_sup_v420 \
  -R "index.html*" \
  -q \
  https://www.bio8.cs.hku.hk/clair3/clair3_models_rerio_pytorch/r1041_e82_400bps_sup_v420/
```

```
In [116]: %%bash

tree config/clair3_models/

config/clair3_models/
├── r1041_e82_400bps_sup_v420
│   ├── full_alignment.pt
│   └── pileup.pt
```

2 directories, 2 files

```
In [117]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

test -d config/clair3_models/r1041_e82_400bps_sup_v420 \
  && echo "Model: OK - config/clair3_models/r1041_e82_400bps_sup_v420" \
  || echo "ERROR: Model chưa được giải nén đúng cấu trúc"
```

Model: OK - config/clair3_models/r1041_e82_400bps_sup_v420

- Nếu sử dụng model download tự động bằng Clair3 thì model sẽ ở trong thư mục cài đặt của Clair3.
- Nếu dùng model tải thủ công, ở lệnh chạy Clair3 thay đường dẫn model cài cùng package bằng folder tải về (trường hợp demo)

```
--model_path=config/clair3_models/r1041_e82_400bps_sup_v420
```

Kiểm tra mv tag trong file BAM

```
In [118]: %%bash

source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

samtools view results/02_alignment/HG002.chr20.bam | grep -o 'mv:B:[^[:space:]]*'
| head
```

Với BAM được tạo bằng cách align FASTQ trong Buổi 4, kết quả không có tag `mv` . Vì vậy:

- không chọn model có hậu tố `_with_mv` ;
- không bật `--enable_dwell_time` .

Không thấy tag trong 20 reads chỉ là kiểm tra nhanh. Provenance của pipeline vẫn là bằng chứng chính để quyết định model.

15. Chạy Clair3

```
In [119]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
# conda activate ont

: <<'COMMENT'

run_clair3.sh \
  --bam_fn=results/02_alignment/HG002.chr20.bam \
  --ref_fn=data/reference/GRCh38.chr20.fa \
  --threads=4 \
  --platform=ont \
  --model_path=config/clair3_models/r1041_e82_400bps_sup_v420 \
  --output=results/03_clair3 \
  --bed_fn=config/target.chr20.bed \
  --sample_name=HG002_CHR20 \
  > logs/clair3.HG002.chr20.stdout.log \
  2> logs/clair3.HG002.chr20.stderr.log

COMMENT

docker run --rm \
  --platform linux/amd64 \
  -v "$PWD":/data \
  hkubal/clair3:v2.0.3 \
  /opt/bin/run_clair3.sh \
  --bam_fn=/data/results/02_alignment/HG002.chr20.bam \
  --ref_fn=/data/data/reference/GRCh38.chr20.fa \
  --threads=4 \
  --platform=ont \
  --model_path=/data/config/clair3_models/r1041_e82_400bps_sup_v420 \
  --output=/data/results/03_clair3 \
  --bed_fn=/data/config/target.chr20.bed \
  --sample_name=HG002_CHR20 \
  > logs/clair3.HG002.chr20.stdout.log \
  2> logs/clair3.HG002.chr20.stderr.log
```

Giải thích tham số

Tham số	Ý nghĩa
--bam_fn	BAM đã coordinate-sort và có index
--ref_fn	Reference FASTA đúng với reference đã dùng khi alignment
--threads	Số CPU threads cho workflow
--platform=ont	Chọn thiết lập cho Oxford Nanopore reads
--model_path	Thư mục model phù hợp với dữ liệu
--output	Thư mục chứa kết quả Clair3
--bed_fn	Chỉ gọi variant trong vùng BED
--sample_name	Tên sample ghi trong VCF
>	Ghi standard output vào log
2>	Ghi standard error vào log riêng

Kiểm tra log

```
In [120]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

tail logs/clair3.HG002.chr20.stdout.log
```

Warning: cannot find your CPU L2 cache size in /proc/cpuinfo

[INFO] 7/7 Merge pileup VCF and full-alignment VCF

Warning: cannot find your CPU L2 cache size in /proc/cpuinfo

[INFO] Pileup variants processed in chr20: 176

[INFO] Full-alignment variants processed in chr20: 411

Warning: cannot find your CPU L2 cache size in /proc/cpuinfo

Warning: cannot find your CPU L2 cache size in /proc/cpuinfo

[INFO] Finish calling, output file: /data/results/03_clair3/merge_output.vcf.gz

16. Tùy chọn không sử dụng trong bài thực hành chính

--pileup_only

Chỉ chạy pileup model. Nhanh hơn nhưng bỏ qua full-alignment stage. Không dùng cho kết quả chính nếu mục tiêu là workflow Clair3 đầy đủ.

--enable_long_indel

Bật chế độ hỗ trợ long indel. Chỉ sử dụng sau khi đọc tài liệu của đúng phiên bản và benchmark trên dữ liệu phù hợp. Không thay thế SV caller.

--enable_dwell_time

Chỉ dùng với model dwell-time phù hợp và BAM có move-table information cần thiết. BAM tạo từ FASTQ bằng minimap2 trong khóa học không đáp ứng điều kiện này.

--qual

Ảnh hưởng việc gán `PASS` hoặc `LowQual` theo ngưỡng QUAL của Clair3. Không tự thay đổi trước khi có benchmark; ghi lại giá trị nếu thay đổi.

17. Liệt kê output

```
In [121]: %%bash
#-----#
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont
#-----#

find results/03_clair3 -maxdepth 2 -type f | sort
```

results/03_clair3/.DS_Store
results/03_clair3/HG002.chr20.Q10.vcf.gz
results/03_clair3/HG002.chr20.demo_filtered.vcf.gz
results/03_clair3/HG002.chr20.demo_filtered.vcf.gz.tbi
results/03_clair3/HG002.chr20.norm.pass.vcf.gz
results/03_clair3/HG002.chr20.norm.pass.vcf.gz.tbi
results/03_clair3/HG002.chr20.norm.stats.txt
results/03_clair3/HG002.chr20.norm.vcf.gz
results/03_clair3/HG002.chr20.norm.vcf.gz.tbi
results/03_clair3/HG002.chr20.variant_table.tsv
results/03_clair3/HG002.chr20.variant_table.with_header.tsv
results/03_clair3/benchmark/HG002.chr20.target_giab_confident.bed
results/03_clair3/benchmark/HG002_GRCh38_v4.2.1.chr20.refchecked.vcf.gz
results/03_clair3/benchmark/HG002_GRCh38_v4.2.1.chr20.refchecked.vcf.gz.tbi
results/03_clair3/benchmark/clair3_HG002_chr20.false_negative.tsv
results/03_clair3/benchmark/clair3_HG002_chr20.false_negatives.tsv
results/03_clair3/benchmark/clair3_HG002_chr20.false_positives.tsv
results/03_clair3/benchmark/clair3_HG002_chr20_happy.extended.csv
results/03_clair3/benchmark/clair3_HG002_chr20_happy.metrics.json.gz
results/03_clair3/benchmark/clair3_HG002_chr20_happy.roc.Locations.INDEL.PASS.csv.gz
results/03_clair3/benchmark/clair3_HG002_chr20_happy.roc.Locations.INDEL.csv.gz
results/03_clair3/benchmark/clair3_HG002_chr20_happy.roc.Locations.SNP.PASS.csv.gz
results/03_clair3/benchmark/clair3_HG002_chr20_happy.roc.Locations.SNP.csv.gz
results/03_clair3/benchmark/clair3_HG002_chr20_happy.roc.all.csv
results/03_clair3/benchmark/clair3_HG002_chr20_happy.runinfo.json
results/03_clair3/benchmark/clair3_HG002_chr20_happy.summary.csv
results/03_clair3/benchmark/clair3_HG002_chr20_happy.tsv
results/03_clair3/benchmark/clair3_HG002_chr20_happy.vcf.gz
results/03_clair3/benchmark/clair3_HG002_chr20_happy.vcf.gz.tbi
results/03_clair3/benchmark/clair3_HG002_chr20_review.tsv
results/03_clair3/full_alignment.vcf.gz
results/03_clair3/full_alignment.vcf.gz.tbi
results/03_clair3/log/1_call_var_bam_pileup.log
results/03_clair3/log/2_select_hetero_snp.log
results/03_clair3/log/3_phase.log
results/03_clair3/log/5_select_candidate.log
results/03_clair3/log/6_call_var_bam_full_alignment.log
results/03_clair3/log/7_merge_vcf.log
results/03_clair3/log/parallel_1_call_var_bam_pileup.log
results/03_clair3/log/parallel_2_select_hetero_snp.log
results/03_clair3/log/parallel_3_phase.log
results/03_clair3/log/parallel_5_select_candidate.log
results/03_clair3/log/parallel_6_call_var_bam_full_alignment.log
results/03_clair3/log/parallel_7_merge_vcf.log
results/03_clair3/merge_output.stats.txt
results/03_clair3/merge_output.vcf.gz
results/03_clair3/merge_output.vcf.gz.tbi
results/03_clair3/pileup.vcf.gz
results/03_clair3/pileup.vcf.gz.tbi
results/03_clair3/run_clair3.log
results/03_clair3/tmp/CHUNK_LIST
results/03_clair3/tmp/CMD
results/03_clair3/tmp/CONTIGS

Kiểm tra file:

```
In [122]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

test -s results/03_clair3/merge_output.vcf.gz && echo "Final VCF: OK"
gzip -t results/03_clair3/merge_output.vcf.gz && echo "gzip integrity: OK"

Final VCF: OK
gzip integrity: OK
```

Mở VCF vừa call:

```
In [123]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools view -h results/03_clair3/merge_output.vcf.gz

bcftools view -H results/03_clair3/merge_output.vcf.gz | head -n2

##fileformat=VCFv4.2
##FILTER=<ID=PASS,Description="All filters passed">
##source=Clair3
##clair3_version=2.0.3
##cmdline=/opt/bin/run_clair3.py --bam_fn=/data/results/02_alignment/HG002.chr2
0.bam --ref_fn=/data/data/reference/GRCh38.chr20.fa --threads=4 --platform=ont -
-model_path=/data/config/clair3_models/r1041_e82_400bps_sup_v420 --output=/data/
results/03_clair3 --bed_fn=/data/config/target.chr20.bed --sample_name=HG002_CHR
20
##reference=/data/data/reference/GRCh38.chr20.fa
##FILTER=<ID=LowQual,Description="Low quality variant">
##FILTER=<ID=RefCall,Description="Reference call">
##INFO=<ID=P,Number=0,Type=Flag,Description="Result from pileup calling">
##INFO=<ID=F,Number=0,Type=Flag,Description="Result from full-alignment callin
g">
##FORMAT=<ID=GT,Number=1,Type=String,Description="Genotype">
##FORMAT=<ID=GQ,Number=1,Type=Integer,Description="Genotype Quality">
##FORMAT=<ID=DP,Number=1,Type=Integer,Description="Approximate read depth (reads
1. with MQ below 5 or an user-specified threshold, or 2. selected by 'samtools v
iew -F 2316', are filtered)">
##FORMAT=<ID=AD,Number=R,Type=Integer,Description="Allelic depths for the ref an
d alt alleles in the order listed">
##FORMAT=<ID=PL,Number=G,Type=Integer,Description="Normalized, Phred-scaled like
lihoods for genotypes as defined in the VCF specification">
##FORMAT=<ID=AF,Number=A,Type=Float,Description="Observed allele frequency in re
ads, for each ALT allele, in the same order as listed, or the REF allele for a R
efCall">
##contig=<ID=chr20,length=64444167>
##bcftools_viewVersion=1.24+htslib-1.24
##bcftools_viewCommand=view -h results/03_clair3/merge_output.vcf.gz; Date=Thu S
ep 24 17:10:44 2026
#CHROM POS ID REF ALT QUAL FILTER INFO FORMAT HG002_CH
R20
chr20 66235 . C CGACT 3.78 PASS F GT:GQ:DP:AD:AF
1/1:3:50:4,1:0.02
chr20 68303 . T C 35.49 PASS P GT:GQ:DP:AD:AF
1/1:35:56:0,56:1
```

Kiểm tra tên sample:

```
In [124]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools query -l results/03_clair3/merge_output.vcf.gz

HG002_CHR20
```

PHẦN 3 – CẤU TRÚC FILE VCF

18. VCF gồm ba phần

18.1 Meta-information

Bắt đầu bằng ## :

```
##fileformat=VCFv4.x
##contig=<ID=chr20,...>
##FILTER=<ID=PASS,...>
##FORMAT=<ID=GT,...>
```

18.2 Header chính

Bắt đầu bằng #CHROM :

```
#CHROM POS ID REF ALT QUAL FILTER INFO FORMAT HG002_CHR20
```

18.3 Variant records

Mỗi dòng mô tả một locus/record biến thể.

Xem header:

```
In [125]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools view -h results/03_clair3/merge_output.vcf.gz

##fileformat=VCFv4.2
##FILTER=<ID=PASS,Description="All filters passed">
##source=Clair3
##clair3_version=2.0.3
##cmdline=/opt/bin/run_clair3.py --bam_fn=/data/results/02_alignment/HG002.chr2
0.bam --ref_fn=/data/data/reference/GRCh38.chr20.fa --threads=4 --platform=ont -
-model_path=/data/config/clair3_models/r1041_e82_400bps_sup_v420 --output=/data/
results/03_clair3 --bed_fn=/data/config/target.chr20.bed --sample_name=HG002_CHR
20
##reference=/data/data/reference/GRCh38.chr20.fa
##FILTER=<ID=LowQual,Description="Low quality variant">
##FILTER=<ID=RefCall,Description="Reference call">
##INFO=<ID=P,Number=0,Type=Flag,Description="Result from pileup calling">
##INFO=<ID=F,Number=0,Type=Flag,Description="Result from full-alignment callin
g">
##FORMAT=<ID=GT,Number=1,Type=String,Description="Genotype">
##FORMAT=<ID=GQ,Number=1,Type=Integer,Description="Genotype Quality">
##FORMAT=<ID=DP,Number=1,Type=Integer,Description="Approximate read depth (reads
1. with MQ below 5 or an user-specified threshold, or 2. selected by 'samtools v
iew -F 2316', are filtered)">
##FORMAT=<ID=AD,Number=R,Type=Integer,Description="Allelic depths for the ref an
d alt alleles in the order listed">
##FORMAT=<ID=PL,Number=G,Type=Integer,Description="Normalized, Phred-scaled like
lihoods for genotypes as defined in the VCF specification">
##FORMAT=<ID=AF,Number=A,Type=Float,Description="Observed allele frequency in re
ads, for each ALT allele, in the same order as listed, or the REF allele for a R
efCall">
##contig=<ID=chr20,length=64444167>
##bcftools_viewVersion=1.24+htslib-1.24
##bcftools_viewCommand=view -h results/03_clair3/merge_output.vcf.gz; Date=Thu S
ep 24 17:10:45 2026
#CHROM POS ID REF ALT QUAL FILTER INFO FORMAT HG002_CH
R20
```

Xem record:

```
In [126]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools view -H results/03_clair3/merge_output.vcf.gz | head -n5

chr20 66235 . C CGACT 3.78 PASS F GT:GQ:DP:AD:AF
1/1:3:50:4,1:0.02
chr20 68303 . T C 35.49 PASS P GT:GQ:DP:AD:AF
1/1:35:56:0,56:1
chr20 72765 . T TA 9.1 PASS F GT:GQ:DP:AD:AF
1/1:9:61:11,18:0.2951
chr20 81154 . T G 35.26 PASS P GT:GQ:DP:AD:AF
1/1:35:83:0,83:1
chr20 85259 . G A 30.52 PASS P GT:GQ:DP:AD:AF
1/1:30:84:0,83:0.9881
```

19. Tám cột VCF cố định

Cột	Ý nghĩa
CHROM	Tên chromosome/contig
POS	Tọa độ 1-based của record
ID	Identifier, ví dụ dbSNP ID; . nếu chưa có
REF	Allele trong reference
ALT	Một hoặc nhiều alternate alleles
QUAL	Điểm chất lượng ở mức site/call; cách hiệu chỉnh phụ thuộc caller
FILTER	PASS , nhãn filter khác hoặc .
INFO	Các annotation ở mức record/site

Sau đó có thể có:

- FORMAT : định nghĩa thứ tự trường của sample
- một hoặc nhiều cột sample.

20. Ví dụ một record VCF

```
chr20    85259    .    G    A    30.52    PASS    P    GT:GQ:DP:AD:AF    1/1:30:84:0,83:0.9881
```

Diễn giải:

- chr20 : chromosome 20.
- 85259 : vị trí 1-based.
- REF = G , ALT = A : SNV G>A .
- QUAL = 30.52 : độ tin cậy ở mức call theo caller.
- FILTER = PASS : record vượt bộ lọc đã được caller áp dụng.
- GT = 1/1 : heterozygous.
- GQ = 30 : chất lượng genotype.
- DP = 84 : depth được caller dùng/báo cáo tại site.
- AD = 0,83 : số quan sát cho REF và ALT theo định nghĩa trong header.
- AF = 0.9881 : allele fraction ALT theo định nghĩa trong header.
- PL : genotype likelihoods dạng Phred-scaled.

Luôn đọc định nghĩa ##INFO và ##FORMAT trong header. Ý nghĩa chi tiết của một tag có thể phụ thuộc caller.

21. Genotype — GT

Với một ALT allele:

GT	Diễn giải diploid
0/0	Homozygous reference
0/1	Heterozygous
1/1	Homozygous alternate
./.	Missing genotype

Với nhiều ALT alleles:

GT	Diễn giải
0/2	REF + ALT thứ hai
1/2	ALT thứ nhất + ALT thứ hai

/ và |

- 0/1 : unphased, chưa biết allele nào thuộc haplotype nào.
- 0|1 : phased, thứ tự haplotype có ý nghĩa theo thông tin phase.

Không đổi / thành | nếu chưa thực hiện phasing.

22. QUAL , GQ , base quality và MAPQ không giống nhau

Chỉ số	Mức áp dụng	Câu hỏi chính
Base quality	Một base trong read	Basecall này có đáng tin không?
MAPQ	Một alignment/read	Read được đặt vào vị trí này có đáng tin không?
QUAL	Variant record/site	Variant call tại site có đáng tin không?
GQ	Genotype của sample	Genotype được gán có đáng tin không?

Các điểm Phred thường có dạng:

$$Q = -10 \times \log_{10}(P_{\text{error}})$$

23. DP , AD và AF

DP — depth

Số reads/observations được caller tính vào depth tại site theo quy tắc của caller.

DP trong VCF có thể khác so với `samtools depth` vì caller có thể lọc reads hoặc bases theo MAPQ, base quality, flags và quy tắc nội bộ.

AD — allele depth

Thường là số quan sát cho:

`REF, ALT1, ALT2, ...`

Ví dụ:

`AD = 18,16`

AF — allele fraction

Tỷ lệ tín hiệu hỗ trợ ALT theo định nghĩa của caller.

Với một sample diploid lý tưởng:

- heterozygous có thể gần 0,5;
- homozygous ALT có thể gần 1,0.

Trong dữ liệu thật, AF không cần đúng chính xác 0,5 hoặc 1,0 vì sampling, allele bias, alignment ambiguity và sequencing errors.

24. PASS , LowQual và dấu chấm

- `PASS` : record vượt các filter được caller áp dụng.
- `LowQual` : caller gắn nhãn chất lượng thấp.
- `.` : chưa áp dụng filter hoặc không có giá trị filter; không đồng nghĩa chắc chắn với `PASS` .

Kiểm tra định nghĩa:

```
In [127]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools view -h results/03_clair3/merge_output.vcf.gz | grep '##FILTER'

##FILTER=<ID=PASS,Description="All filters passed">
##FILTER=<ID=LowQual,Description="Low quality variant">
##FILTER=<ID=RefCall,Description="Reference call">
```

FILTER		Ý nghĩa
PASS		Variant đã vượt qua tất cả tiêu chí lọc
LowQual		Variant được gọi nhưng chất lượng thấp, không đạt ngưỡng
RefCall	Caller cho rằng vị trí này phù hợp với reference , tức không phải một variant đáng tin cậy	

PHẦN 4 — NORMALIZE VCF

25. Tại sao cần normalize?

Trong vùng lặp, cùng một indel có thể có nhiều cách biểu diễn tương đương. Chuẩn hóa giúp:

- left-align indel;
- kiểm tra REF bằng reference FASTA;
- biểu diễn allele tối giản;
- tách multiallelic records thành biallelic records khi cần;
- so sánh giữa các VCF nhất quán hơn.

Normalization có thể làm thay đổi POS , REF , ALT của record nhưng không nhất thiết làm thay đổi biến cố sinh học.

26. Normalize và tách multiallelic records

```
In [128]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools norm \
  -f data/reference/GRCh38.chr20.fa \
  -m -any \
  -Oz \
  -o results/03_clair3/HG002.chr20.norm.vcf.gz \
  results/03_clair3/merge_output.vcf.gz

Lines total/split/joined/realigned/mismatch_removed/dup_removed/skipped:
587/5/0/1/0/0/0
```

Lập index:

```
In [129]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools index -t results/03_clair3/HG002.chr20.norm.vcf.gz
```

Giải thích

Tham số	Ý nghĩa
-f	Reference dùng để left-align và kiểm tra REF
-m -any	Tách multiallelic record thành các biallelic records
-O z	Xuất VCF nén bgzip
-o	Tên file output

Nếu nhận lỗi REF mismatch, không dùng tùy chọn để bỏ qua. Kiểm tra lại build reference và FASTA đã dùng khi alignment.

PHẦN 5 – THỐNG KÊ FILE VCF

27. Báo cáo tổng hợp bằng `bcftools stats`

```
In [130]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools stats -s - results/03_clair3/HG002.chr20.norm.vcf.gz > results/03_clair3/HG002.chr20.norm.stats.txt

# bcftools stats -s - results/03_clair3/merge_output.vcf.gz > results/03_clair3/merge_output.stats.txt
```

Xem các dòng summary:

```
In [131]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

grep '^SN' results/03_clair3/HG002.chr20.norm.stats.txt
```

```
SN      0      number of samples:      1
SN      0      number of records:      592
SN      0      number of no-ALTs:      0
SN      0      number of SNPs: 488
SN      0      number of MNPs: 0
SN      0      number of indels:      104
SN      0      number of others:      0
SN      0      number of multiallelic sites: 0
SN      0      number of multiallelic SNP sites: 0
```

Xem transition/transversion:

```
In [132]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

grep '^TSTV' results/03_clair3/HG002.chr20.norm.stats.txt
```

```
TSTV      0      341      147      2.32      341      147      2.32
```

Xem phân bố substitution nếu có:

```
In [133]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

grep '^ST' results/03_clair3/HG002.chr20.norm.stats.txt | head
```

```
ST      0      A>C      26
ST      0      A>G      60
ST      0      A>T      14
ST      0      C>A      18
ST      0      C>G      22
ST      0      C>T      78
ST      0      G>A      109
ST      0      G>C      22
ST      0      G>T      16
ST      0      T>A      13
```

Các nhóm dòng trong báo cáo có mã ở cột đầu. Đọc phần mô tả đầu file trước khi trích số liệu:

```
In [134]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

cat results/03_clair3/HG002.chr20.norm.stats.txt | grep SN | head -n14

# SN, Summary numbers:
#   number of SNPs           .. number of rows with a SNP
#   number of multiallelic SNP sites .. number of rows with multiple alternate alleles, all SNPs
#   counter. For example, a row with a SNP and an indel increments both the SNP and
# SN      [2]id      [3]key  [4]value
SN        0         number of samples:      1
SN        0         number of records:      592
SN        0         number of no-ALTs:       0
SN        0         number of SNPs: 488
SN        0         number of MNPs: 0
SN        0         number of indels:       104
SN        0         number of others:       0
SN        0         number of multiallelic sites: 0
SN        0         number of multiallelic SNP sites: 0
```

28. Đếm tổng số record

```
In [135]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools view -H results/03_clair3/HG002.chr20.norm.vcf.gz | wc -l

592
```

-H bỏ header và chỉ in variant records.

29. Đếm record PASS

```
In [136]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools view -f PASS -H results/03_clair3/HG002.chr20.norm.vcf.gz | wc -l

574
```

So sánh với tổng số record để biết có bao nhiêu record không mang nhãn PASS .

30. Đếm SNV, MNV và indel

Sau khi đã tách multiallelic records:

```
In [137]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

echo -n "SNV:   "
bcftools view -v snps -H results/03_clair3/HG002.chr20.norm.vcf.gz | wc -l

echo -n "MNV:   "
bcftools view -v mnps -H results/03_clair3/HG002.chr20.norm.vcf.gz | wc -l

echo -n "INDEL: "
bcftools view -v indels -H results/03_clair3/HG002.chr20.norm.vcf.gz | wc -l

echo -n "OTHER: "
bcftools view -v other -H results/03_clair3/HG002.chr20.norm.vcf.gz | wc -l

SNV:           488
MNV:            0
INDEL:         104
OTHER:          0
```

Chỉ đếm PASS :

```
In [138]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont
echo -n "SNV:   "
bcftools view -f PASS -v snps -H results/03_clair3/HG002.chr20.norm.vcf.gz | wc -l

echo -n "INDEL: "
bcftools view -f PASS -v indels -H results/03_clair3/HG002.chr20.norm.vcf.gz | wc -l

SNV:           486
INDEL:          88
```

31. Thống kê 12 kiểu thay thế nucleotide

Chỉ lấy PASS, biallelic SNVs:

```
In [139]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools view \
  -f PASS \
  -m2 -M2 \
  -v snps \
  -Ou results/03_clair3/HG002.chr20.norm.vcf.gz \
  | bcftools query -f '%REF>%ALT\n' \
  | sort \
  | uniq -c \
  | sort -nr
```

```
108 G>A
 94 T>C
 78 C>T
 60 A>G
 25 A>C
 22 G>C
 22 C>G
 18 C>A
 16 T>G
 16 G>T
 14 A>T
 13 T>A
```

Tại sao cần **-m2 -M2** ?

- **-m2** : record có ít nhất 2 alleles tính cả REF.
- **-M2** : record có nhiều nhất 2 alleles tính cả REF.
- Kết hợp hai tùy chọn: chỉ giữ biallelic records.

32. Thống kê genotype

Với VCF một sample:

```
In [140]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools query -f ' [%GT\n]' -i 'FILTER="PASS"' results/03_clair3/HG002.chr20.norm.vcf.gz \
  | sort \
  | uniq -c \
  | sort -nr
```

```
430 0/1
142 1/1
  2 1/0
```

Không gộp phased và unphased genotype nếu câu hỏi phân tích cần giữ thông tin phase.

33. Thống kê chiều dài indel

```
In [141]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools view \
  -f PASS \
  -m2 -M2 \
  -v indels \
  -Ou results/03_clair3/HG002.chr20.norm.vcf.gz \
  | bcftools query -f '%REF\t%ALT\n' \
  | awk '{print length($2)-length($1)}' \
  | sort -n \
  | uniq -c

1 -24
1 -17
1 -9
2 -8
1 -7
2 -6
4 -4
4 -3
9 -2
16 -1
19 1
9 2
2 3
4 4
1 5
2 6
2 8
1 9
1 10
1 13
1 16
1 21
1 28
1 33
1 44
```

Cách đọc giá trị:

- số dương: insertion;
- số âm: deletion;
- trị tuyệt đối: chênh lệch chiều dài allele.

34. Trích xuất variant table

```
In [142]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools query \
  -f '%CHROM\t%POS\t%REF\t%ALT\t%QUAL\t%FILTER[\t%GT\t%GQ\t%DP\t%AD\t%AF]\n' \
  results/03_clair3/HG002.chr20.norm.vcf.gz \
  > results/03_clair3/HG002.chr20.variant_table.tsv
```

Thêm header:

```
In [143]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

{
  printf 'CHROM\tPOS\tREF\tALT\tQUAL\tFILTER\tGT\tGQ\tDP\tAD\tAF\n'
  cat results/03_clair3/HG002.chr20.variant_table.tsv
} > results/03_clair3/HG002.chr20.variant_table.with_header.tsv
```

Xem cột thẳng hàng:

```
In [144]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

column -t -s $'\t' \
  results/03_clair3/HG002.chr20.variant_table.with_header.tsv \
  | head
```

CHROM	POS	REF	ALT
QUAL	FILTER	GT	GQ DP AD AF
chr20	66235	C	CGACT
3.78	PASS	1/1	3 50 4,1 0.02
chr20	68303	T	C
35.49	PASS	1/1	35 56 0,56 1
chr20	72765	T	TA
9.1	PASS	1/1	9 61 11,18 0.2951
chr20	81154	T	G
35.26	PASS	1/1	35 83 0,83 1
chr20	85259	G	A
30.52	PASS	1/1	30 84 0,83 0.9881
chr20	85729	G	A
35.45	PASS	1/1	35 83 1,79 0.9518
chr20	86859	T	TTGGTATCTAG
34.21	PASS	1/1	34 89 2,82 0.9213
chr20	88108	T	C
22.07	PASS	0/1	22 96 49,47 0.4896
chr20	91463	TA	T
29.03	PASS	1/1	29 107 2,105 0.9813

```
Kiểm tra header trước bằng bcftools view -h .
```

35. So sánh số variant trước và sau normalization

```
In [145]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

echo -n "Before normalization: "
bcftools view -H results/03_clair3/merge_output.vcf.gz | wc -l

echo -n "After split/normalization: "
bcftools view -H results/03_clair3/HG002.chr20.norm.vcf.gz | wc -l

Before normalization:      587
After split/normalization:  592
```

Kiểm tra multiallelic variants:

```
In [146]: %%bash
bcftools view -H results/03_clair3/merge_output.vcf.gz | \
awk 'BEGIN{FS="\t"} {n=split($5,a,","); if(n>1) print $1"\t"$2"\t"$4"\t"$5}'

chr20    102609    CTGTGTGTGTGTGTGTGTGTGTGTGTG      C,CTGTGTGTGTGTGTGTGTGTGTGTGTG
chr20    128517    C          CAA,CA
chr20    159274    T          TAAAAAA,TAAA
chr20    165108    C          T,CAT
chr20    236959    C          CTT,CT
```

Chú thích:

- `FS="\t"` : các cột VCF được ngăn cách bằng tab
- `$5` : cột ALT
- `split($5,a,",")` : tách ALT theo , và lưu vào array a
- `n` : số lượng ALT allele
- `if(n>1)` : chỉ giữ multiallelic variants
- `$1, $2, $4, $5` : in CHROM, POS, REF, ALT

PHẦN 6 — LỌC VARIANT

36. Giữ lại record PASS

```
In [147]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools view \
  -f PASS \
  -Oz \
  -o results/03_clair3/HG002.chr20.norm.pass.vcf.gz \
  results/03_clair3/HG002.chr20.norm.vcf.gz

bcftools index -t results/03_clair3/HG002.chr20.norm.pass.vcf.gz

bcftools view -H results/03_clair3/HG002.chr20.norm.pass.vcf.gz | wc -l
```

574

37. Ví dụ filter

Ví dụ minh họa:

```
In [148]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools view \
  -f PASS \
  -i 'QUAL>=20 && FMT/DP>=10 && FMT/GQ>=20' \
  -Oz \
  -o results/03_clair3/HG002.chr20.demo_filtered.vcf.gz \
  results/03_clair3/HG002.chr20.norm.vcf.gz

bcftools index -t results/03_clair3/HG002.chr20.demo_filtered.vcf.gz

echo -n "No. Variant: "
bcftools view -H results/03_clair3/HG002.chr20.demo_filtered.vcf.gz | wc -l
```

No. Variant: 514

Chú thích điều kiện

- QUAL>=20 : điểm site/call từ 20 trở lên.
- FMT/DP>=10 : sample depth từ 10 trở lên.
- FMT/GQ>=20 : genotype quality từ 20 trở lên.

Cảnh báo quan trọng

Các ngưỡng trên chỉ để học cú pháp, không phải ngưỡng lâm sàng hoặc ngưỡng tối ưu cho mọi bộ dữ liệu. Muốn chốt filter cần:

- benchmark bằng truth set phù hợp;
- đánh giá precision/recall;
- xem mục đích phân tích;
- xem coverage và chemistry;
- ghi lại version caller và model.

Không nên dùng AF gần 0,5 như điều kiện bắt buộc cho mọi heterozygous variant.

38. Đếm variant trước và sau filter

```
In [149]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

printf 'All normalized records: '
bcftools view -H results/03_clair3/HG002.chr20.norm.vcf.gz | wc -l

printf 'PASS records: '
bcftools view -H results/03_clair3/HG002.chr20.norm.pass.vcf.gz | wc -l

printf 'Demo-filtered records: '
bcftools view -H results/03_clair3/HG002.chr20.demo_filtered.vcf.gz | wc -l

All normalized records:      592
PASS records:                574
Demo-filtered records:      514
```

PHẦN 7 — KIỂM TRA VARIANT TRÊN IGV

39. Chọn variant để kiểm tra

Xuất 10 PASS variants có QUAL cao:

```
In [150]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools query \
  -f '%CHROM\t%POS\t%REF\t%ALT\t%QUAL\t%FILTER[\t%GT\t%DP\t%AD\t%AF]\n' \
  results/03_clair3/HG002.chr20.norm.pass.vcf.gz \
  | sort -t $'\t' -k5,5nr \
  | head -n 10
```

chr20	130339	T	C	41.03	PASS	1/1	89	0,89	1
chr20	244417	A	G	40.47	PASS	1/1	80	2,76	0.95
chr20	154290	T	G	40.08	PASS	1/1	91	0,89	0.978
chr20	238370	A	G	39.85	PASS	1/1	83	0,83	1
chr20	308968	G	C	39.68	PASS	1/1	75	0,71	0.9467
chr20	111886	A	G	39.55	PASS	1/1	108	3,95	0.8796
chr20	144480	C	T	39.27	PASS	1/1	88	3,78	0.8864
chr20	242614	T	G	39.26	PASS	1/1	81	3,77	0.9506
chr20	110447	C	T	39.07	PASS	1/1	112	1,110	0.9821
chr20	96321	T	C	39.03	PASS	1/1	118	0,112	0.9492

40. File cần load vào IGV

1. Reference GRCh38 phù hợp.
2. results/02_alignment/HG002.chr20.sorted.bam
3. results/02_alignment/HG002.chr20.sorted.bam.bai
4. results/03_clair3/HG002.chr20.norm.pass.vcf.gz
5. results/03_clair3/HG002.chr20.norm.pass.vcf.gz.tbi
6. BED vùng đích nếu cần.

41. Checklist quan sát trên IGV

Tại mỗi variant, kiểm tra:

- Vị trí có đủ coverage hay không.
- ALT có được nhiều reads độc lập hỗ trợ hay không.
- Reads hỗ trợ có MAPQ hợp lý hay không.
- Variant có nằm gần đầu/cuối nhiều read hay không.
- Có cụm mismatch dày đặc quanh vị trí hay không.
- Có homopolymer hoặc low-complexity sequence hay không.
- Indel có được biểu diễn nhất quán giữa nhiều reads hay không.
- Có strand bias hoặc alignment ambiguity rõ rệt hay không.

Lưu ý

- Nhìn thấy màu mismatch không tự động chứng minh variant thật.
- Không nhìn thấy một insertion dài đầy đủ trên màn hình không tự động chứng minh call sai.
- IGV có thể downsample reads khi coverage cao.
- Reads màu xám/trắng có thể do color setting, selection hoặc shading; cần xem legend và track settings.
- Vùng reference có N hoặc repeat có thể làm alignment và biểu diễn indel khó diễn giải.

IGV là công cụ kiểm tra trực quan, không thay thế benchmark với truth set.

PHẦN 8 – SO SÁNH VỚI GIAB TRUTH SET

42. Mục tiêu của benchmarking

Sau khi Clair3 tạo VCF, câu hỏi quan trọng không chỉ là “có bao nhiêu variant?” mà còn là:

- Bao nhiêu variant đúng so với benchmark?
- Bao nhiêu variant thật bị bỏ sót?
- Bao nhiêu call không khớp với benchmark?
- Hiệu năng đối với SNV và INDEL có khác nhau không?
- Filter hiện tại ưu tiên precision hay recall?

Trong phần này, VCF của Clair3 được so sánh với small-variant benchmark của **Genome in a Bottle (GIAB)** cho mẫu HG002.

Nên gọi đây là **benchmark truth set** thay vì “sự thật tuyệt đối”. Truth set cũng có phạm vi, phiên bản và giới hạn riêng.

43. Ba thành phần bắt buộc của benchmark

43.1 Truth VCF

Truth VCF chứa các genotype benchmark của HG002.

HG002_GRCh38_1_22_v4.2.1_benchmark.vcf.gz

43.2 Confident-region BED

BED xác định những vùng mà GIAB cho phép đánh giá đáng tin cậy.

```
HG002_GRCh38_1_22_v4.2.1_benchmark_noinconsistent.bed
```

43.3 Reference FASTA phù hợp

Reference dùng cho:

- alignment;
- Clair3;
- truth VCF;
- hap.py.

phải cùng build và cùng trình tự.

Không được chỉ nhìn thấy chữ GRCh38 rồi mặc định mọi FASTA GRCh38 đều giống nhau. Các bản có ALT contigs, decoys, patch hoặc naming convention khác nhau có thể không tương thích.

44. Truth VCF và confident BED phải đi cùng nhau

Truth VCF trả lời:

Trong vùng benchmark, những variant/genotype nào được GIAB xác định?

Confident BED trả lời:

Ở những vị trí nào GIAB cho phép đánh giá TP, FP và FN?

Không nên benchmark chỉ bằng truth VCF mà bỏ confident BED.

Một query call ngoài confident BED thường được xem là **UNK/non-assessed**, không nên tự động gọi là FP.

45. Tại sao phải lấy giao với BED của khóa học?

Clair3 trong khóa học chỉ gọi variant trong:

config/target.chr20.bed

Nếu so query VCF này với toàn bộ confident region trên chr20:

- truth variants nằm ngoài target BED sẽ không thể xuất hiện trong query;
- các variant đó sẽ bị tính sai thành FN;
- recall sẽ sai lệch.

Vùng đánh giá đúng phải là:

target BED $\cap$ GIAB confident BED

Target region của khóa học

$\cap$

GIAB confident region

$\downarrow$

Vùng benchmark thực sự

46. TP, FP, FN và UNK

Ký hiệu	Tên	Diễn giải trong benchmark
TP	True positive	Query khớp truth về allele/haplotype và genotype theo quy tắc benchmark
FP	False positive	Query call trong confident region nhưng không khớp truth
FN	False negative	Truth variant trong vùng đánh giá nhưng query bỏ sót hoặc không khớp
UNK	Unknown/non-assessed	Query call ngoài confident region hoặc không thuộc phạm vi đánh giá

Một genotype mismatch có thể tạo đồng thời:

- một FP ở phía query;
- một FN ở phía truth.

Ví dụ:

Truth GT = 0/1

Query GT = 1/1

47. Precision, recall và F1-score

Recall/Sensitivity

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

Ý nghĩa:

Trong số variant thật thuộc phạm vi benchmark, pipeline tìm được bao nhiêu?

Recall cao nghĩa là ít bỏ sót.

Precision

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

Ý nghĩa:

Trong số variant query gọi ra trong vùng benchmark, bao nhiêu call khớp truth?

Precision cao nghĩa là ít false positive.

F1-score

$$\text{F1} = 2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$$

F1 là trung bình điều hòa của precision và recall. F1 chỉ có ý nghĩa khi hiểu rõ vùng benchmark và loại variant đang được đánh giá.

Ví dụ minh họa

Nếu:

TP = 90

FP = 5

FN = 10

thì:

Recall = $90 / (90 + 10) = 0.9000$

Precision = $90 / (90 + 5) = 0.9474$

F1 ≈ 0.9231

48. Tại sao không dùng `bcftools isec` làm benchmark chính?

Hai VCF có thể mô tả cùng một alternate haplotype bằng các record khác nhau.

Ví dụ:

- caller A biểu diễn một complex variant bằng một record;
- caller B biểu diễn cùng haplotype bằng một SNV và một indel;
- vị trí/REF/ALT không giống từng dòng dù sequence cuối cùng giống nhau.

`bcftools isec` rất hữu ích để so sánh record/allele đã chuẩn hóa, nhưng không giải quyết đầy đủ mọi khác biệt về haplotype representation.

`hap.py` được chọn vì nó:

- tiền xử lý variant representation;
- so sánh diploid genotype ở mức haplotype;
- dùng confident-region BED;
- báo cáo riêng SNP và INDEL;
- tính TP, FP, FN, UNK, precision, recall và F1.

`bcftools isec` có thể được dùng như bài minh họa bổ sung, không thay thế kết quả `hap.py`.

49. Cài `hap.py` trong environment riêng

`hap.py` trên Bioconda chỉ hỗ trợ Linux x86-64 và có dependency Python 2.7 cũ. Vì vậy không cài vào environment `clair3`.

```
In [151]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

:<< 'Danh cho Ubuntu'
conda create -n happy \
  -c conda-forge \
  -c bioconda \
  -y hap.py=0.3.15 bcftools=1.22 bedtools=2.31.1 samtools=1.22
COMMENT

## MAC M1/2
# docker pull quay.io/biocontainers/hap.py:0.3.15--py27hcb73b3d_0
```

Kích hoạt:

```
In [152]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"

conda activate ont

which hap.py
hap.py --version
bcftools --version | head -n 1
bedtools --version
samtools --version | head -n 1

bash: line 6: hap.py: command not found

bcftools 1.24
bedtools v2.31.1
samtools 1.24
```

```
In [153]: %%bash

mkdir -p \
  data/reference/giab/HG002_v4.2.1_GRCh38 \
  results/03_clair3/benchmark \
  logs
```

50. Tải GIAB HG002 v4.2.1 cho GRCh38

Truth VCF

```
In [154]: %%bash

mkdir -p data/reference/giab/HG002_v4.2.1_GRCh38

wget \
  -O data/reference/giab/HG002_v4.2.1_GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark.vcf.gz \
  -q \
  'https://ftp-trace.ncbi.nlm.nih.gov/ReferenceSamples/giab/release/AshkenazimTrio/HG002_NA24385_son/NISTv4.2.1/GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark.vcf.gz'
```

Truth VCF index

```
In [155]: %%bash

wget \
  -O data/reference/giab/HG002_v4.2.1_GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark.vcf.gz.tbi \
  -q \
  'https://ftp-trace.ncbi.nlm.nih.gov/ReferenceSamples/giab/release/AshkenazimTrio/HG002_NA24385_son/NISTv4.2.1/GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark.vcf.gz.tbi'
```

Confident-region BED

```
In [156]: %%bash

wget \
  -O data/reference/giab/HG002_v4.2.1_GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark_noinconsistent.bed \
  -q \
  'https://ftp-trace.ncbi.nlm.nih.gov/ReferenceSamples/giab/release/AshkenazimTrio/HG002_NA24385_son/NISTv4.2.1/GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark_noinconsistent.bed'
```

Không thay đường dẫn NISTv4.2.1/GRCh38 bằng thư mục latest nếu muốn khóa học tái lập đúng phiên bản.

51. Kiểm tra file tải về

Kiểm tra file tồn tại và có kích thước lớn hơn 0:

```
In [157]: %%bash

ls -lh data/reference/giab/HG002_v4.2.1_GRCh38

total 354328
-rw-r--r--  1 lamnguyen  staff   149M Dec  7  2020 HG002_GRCh38_1_22_v4.2.1_benchmark.vcf.gz
-rw-r--r--  1 lamnguyen  staff   1.6M Dec  7  2020 HG002_GRCh38_1_22_v4.2.1_benchmark.vcf.gz.tbi
-rw-r--r--  1 lamnguyen  staff    11M Dec  4  2020 HG002_GRCh38_1_22_v4.2.1_benchmark_noinconsistent.bed
```

Kiểm tra gzip:

```
In [158]: %%bash

gzip -t \
  data/reference/giab/HG002_v4.2.1_GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark.vcf.gz \
  && echo "GIAB truth VCF gzip: OK"

GIAB truth VCF gzip: OK
```

Kiểm tra index có sử dụng được:

```
In [159]: %%bash

source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools index -n \
  data/reference/giab/HG002_v4.2.1_GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark.vcf.gz

4048342
```

Kiểm tra sample:

```
In [160]: %%bash

source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools query -l \
  data/reference/giab/HG002_v4.2.1_GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark.vcf.gz

HG002
```

Kết quả phải là HG002 hoặc identifier tương ứng của HG002, không phải HG001/HG003/HG004.

Kiểm tra BED không có UCSC track header:

```
In [161]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

head \
  data/reference/giab/HG002_v4.2.1_GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark_noin
consistent.bed
```

chr1	601181	604320
chr1	604424	605001
chr1	605103	605736
chr1	605838	607569
chr1	607922	609269
chr1	610766	611301
chr1	628710	629969
chr1	630071	632981
chr1	633134	633654
chr1	633676	634959

52. Kiểm tra naming convention

Truth VCF

```
In [162]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools index -s \
  data/reference/giab/HG002_v4.2.1_GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark.vcf.
gz \
  | head
```

chr1	248956422	319349
chr2	242193529	327461
chr3	198295559	285177
chr4	190214555	304062
chr5	181538259	261422
chr6	170805979	268327
chr7	159345973	231884
chr8	145138636	222780
chr9	138394717	174154
chr10	133797422	210970

GIAB confident BED

```
In [163]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

cut -f1 \
    data/reference/giab/HG002_v4.2.1_GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark_noin
consistent.bed \
    | sort -u \
    | head

chr1
chr10
chr11
chr12
chr13
chr14
chr15
chr16
chr17
chr18
```

Dữ liệu tham chiếu

```
In [164]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

cut -f1,2 data/reference/GRCh38.chr20.fa.fai

chr20    64444167
```

Target BED

```
In [165]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

cut -f1 config/target.chr20.bed \
    | sort -u

chr20
```

Clair3 VCF

```
In [166]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools index -s results/03_clair3/merge_output.vcf.gz

chr20    64444167    587
```

Tất cả phải dùng cùng tên contig, trong bài này là:

chr20

Không dựa hoàn toàn vào `hap.py --fixchr` để xoá lỗi sai chr. Nếu naming convention không khớp, xác định nguyên nhân trước.

53. Kiểm tra sample của query VCF

```
In [167]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools query -l results/03_clair3/merge_output.vcf.gz

HG002_CHR20
```

Tên sample trong truth và query không bắt buộc phải giống từng ký tự khi mỗi VCF chỉ có một sample, nhưng cả hai phải thực sự mô tả cùng vật liệu HG002.

Kiểm tra số sample:

```
In [168]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools query -l \
    data/reference/giab/HG002_v4.2.1_GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark.vcf.
gz \
| wc -l

bcftools query -l results/03_clair3/merge_output.vcf.gz \
| wc -l

1
1
```

Cả hai lệnh phải trả về:

1

54. Kiểm tra reference compatibility trên chr20

Tạo truch VCF chr20 đồng thời yêu cầu bcftools dừng nếu REF không khớp reference:

```
In [169]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools norm \
  -f data/reference/GRCh38.chr20.fa \
  -c e \
  -r chr20 \
  -Oz \
  -o results/03_clair3/benchmark/HG002_GRCh38_v4.2.1.chr20.refchecked.vcf.gz \
  data/reference/giab/HG002_v4.2.1_GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark.vcf.
gz
# 2> logs/giab.HG002.chr20.refcheck.log
```

```
Lines    total/split/joined/realigned/mismatch_removed/dup_removed/skipped:
85951/0/0/1/0/0/0
```

Lập index:

```
In [170]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools index -t \
  results/03_clair3/benchmark/HG002_GRCh38_v4.2.1.chr20.refchecked.vcf.gz
```

Ý nghĩa -c e

-c e yêu cầu bcftools thoát với lỗi khi allele REF trong VCF không khớp sequence của FASTA.

Nếu có REF mismatch:

1. Dừng benchmark.
2. Xác nhận FASTA đã dùng cho minimap2 và Clair3.
3. Kiểm tra FASTA có đúng GRCh38 no-alt analysis set tương ứng hay không.
4. Không dùng plugin `fixref` hoặc đổi REF/ALT để “làm cho chạy được” khi chưa xác định nguyên nhân.
5. Nếu reference thật sự khác, cần align và gọi variant lại với reference phù hợp.

Không liftover query VCF rồi coi đó là benchmark tương đương với việc gọi variant trên đúng reference.

55. Tạo vùng đánh giá: $\text{target} \cap \text{confident region}$

```
In [171]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bedtools intersect \
  -a config/target.chr20.bed \
  -b data/reference/giab/HG002_v4.2.1_GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark_n
oinconsistent.bed \
  | bedtools sort -i - \
  | bedtools merge -i - \
  > results/03_clair3/benchmark/HG002.chr20.target_giab_confident.bed
```

Kiểm tra BED kết quả

```
In [172]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

head results/03_clair3/benchmark/HG002.chr20.target_giab_confident.bed

chr20    81335    101267
chr20    101308    102558
chr20    102684    105312
chr20    105417    112950
chr20    113052    115904
chr20    116012    128466
chr20    128568    132145
chr20    132167    135832
chr20    135853    140801
chr20    140931    148813
```

```
In [173]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

wc -l results/03_clair3/benchmark/HG002.chr20.target_giab_confident.bed

52 results/03_clair3/benchmark/HG002.chr20.target_giab_confident.bed
```

Tính tổng số base có thể đánh giá:

```
In [174]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

awk '{sum += $3-$2} END {print "Assessable bases:", sum}' \
results/03_clair3/benchmark/HG002.chr20.target_giab_confident.bed

Assessable bases: 247691
```

Vì sao cần sort và merge ?

hap.py -R yêu cầu các intervals không chồng lấn. bedtools merge tạo một vùng đánh giá không overlap sau khi lấy giao.

56. Kiểm tra số record trong vùng đánh giá trước khi benchmark

Truth records:

```
In [175]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools view \
-R results/03_clair3/benchmark/HG002.chr20.target_giab_confident.bed \
--regions-overlap 1 \
-H \
results/03_clair3/benchmark/HG002_GRCh38_v4.2.1.chr20.refchecked.vcf.gz \
| wc -l

514
```

Query records:

```
In [176]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools view \
  -R results/03_clair3/benchmark/HG002.chr20.target_giab_confident.bed \
  --regions-overlap 1 \
  -H \
  results/03_clair3/HG002.chr20.norm.vcf.gz \
  | wc -l
```

512

PASS query records:

```
In [177]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools view \
  -f PASS \
  -R results/03_clair3/benchmark/HG002.chr20.target_giab_confident.bed \
  --regions-overlap 1 \
  -H \
  results/03_clair3/HG002.chr20.norm.vcf.gz \
  | wc -l
```

509

Các lệnh này chỉ là kiểm tra sơ bộ số record. Chúng không thay thế haplotype-aware comparison của hap.py.

57. Chạy hap.py

Chạy benchmark:

```
In [178]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

# hap.py \
# results/03_clair3/benchmark/HG002_GRCh38_v4.2.1.chr20.refchecked.vcf.gz \
# results/03_clair3/HG002.chr20.norm.vcf.gz \
# -f results/03_clair3/benchmark/HG002.chr20.target_giab_confident.bed \
# -R results/03_clair3/benchmark/HG002.chr20.target_giab_confident.bed \
# -r data/reference/GRCh38.chr20.fa \
# -o results/03_clair3/benchmark/clair3_HG002_chr20_happy \
# --engine=xcmp \
# --threads 4 \
# --pass-only \
# -l chr20 \
# -V \
# > logs/happy.clair3_HG002_chr20.stdout.log \
# 2> logs/happy.clair3_HG002_chr20.stderr.log

rm -rf results/03_clair3/benchmark/clair3_HG002_chr20_happy*
docker run --platform linux/amd64 --rm \
-v "$PWD":/data \
quay.io/biocontainers/hap.py:0.3.15--py27hcb73b3d_0 \
hap.py \
/data/results/03_clair3/benchmark/HG002_GRCh38_v4.2.1.chr20.refchecked.vcf.gz \
/data/results/03_clair3/HG002.chr20.norm.vcf.gz \
-f /data/results/03_clair3/benchmark/HG002.chr20.target_giab_confident.bed \
-R /data/results/03_clair3/benchmark/HG002.chr20.target_giab_confident.bed \
-r /data/data/reference/GRCh38.chr20.fa \
-o /data/results/03_clair3/benchmark/clair3_HG002_chr20_happy \
--engine=xcmp \
--threads 4 \
-l chr20 \
-V \
> logs/happy.clair3_HG002_chr20.stdout.log \
2> logs/happy.clair3_HG002_chr20.stderr.log
```

Giải thích tham số

Thành phần	Ý nghĩa
VCF thứ nhất	Truth VCF
VCF thứ hai	Query VCF từ Clair3
-f	Confident-call region dùng để quyết định call nào được đánh giá
-R	Giới hạn phép so sánh vào đúng vùng target-confident đã merge
-r	Reference FASTA dùng để tạo và so sánh haplotype
-o	Prefix của các output files
--engine=xcmp	Dùng haplotype-matching engine mặc định của hap.py một cách tường minh
--threads 4	Sử dụng 4 threads
--pass-only	Chỉ đánh giá variants vượt filter trong query/truth
-l chr20	Chỉ xử lý chromosome 20; cần thiết vì reference của khóa học chỉ chứa chr20
-V	Xuất annotated comparison VCF

Tại sao dùng cả `-f` và `-R` ?

- `-f` định nghĩa confident regions cho việc phân loại TP/FP/FN/UNK.
- `-R` giới hạn computation vào vùng target của khóa học đã giao với confident BED.

Nếu bỏ `-R`, calls ngoài target-confident có thể vẫn xuất hiện trong intermediate comparison và được phân loại UNK. Nếu dùng confident BED toàn chr20 thay vì BED giao, truth variants ngoài target có thể bị tính thành FN.

Vì sao bài chính dùng `xcmp` thay vì `vcfeval` ?

- `xcmp` là engine haplotype-aware mặc định đi cùng hap.py.
- `vcfeval` cần RTG Tools, Java và reference ở dạng SDF; support phải có trong bản hap.py được cài.
- Với lớp nhập môn, `xcmp` giảm số dependency và vẫn giải quyết tốt khác biệt representation ở mức haplotype.

Đối với benchmark chính thức hoặc publication, có thể chạy thêm `vcfeval` trong container/environment đã integration-test. Không chỉ thêm `--engine=vcfeval` vào command nếu installation chưa có RTG Tools và SDF reference.

58. Kiểm tra hap.py có chạy thành công không

Xem standard error:

```
In [179]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

head logs/happy.clair3_HG002_chr20.stderr.log
```

```
2026-09-24 22:11:26,831 WARNING No reference file found at default locations. You can set the environment variable 'HGREF' or 'HG19' to point to a suitable Fasta file.
```

```
[I] Total VCF records: 85951
```

```
[I] Non-reference VCF records: 85951
```

```
[I] Total VCF records: 592
```

```
[I] Non-reference VCF records: 592
```

```
2026-09-24 22:11:29,679 WARNING [W::bcf_hdr_register_hrec] The definition of Flag "INFO/IMPORT_FAIL" is invalid, forcing Number=0
```

```
2026-09-24 22:11:29,680 WARNING [W::bcf_hdr_register_hrec] The definition of Flag "INFO/IMPORT_FAIL" is invalid, forcing Number=0
```

```
2026-09-24 22:11:29,680 WARNING [W::bcf_hdr_register_hrec] The definition of Flag "INFO/IMPORT_FAIL" is invalid, forcing Number=0
```

```
2026-09-24 22:11:30,036 WARNING [W::bcf_hdr_register_hrec] The definition of Flag "INFO/IMPORT_FAIL" is invalid, forcing Number=0
```

```
2026-09-24 22:11:30,186 WARNING [W::bcf_hdr_register_hrec] The definition of Flag "INFO/IMPORT_FAIL" is invalid, forcing Number=0
```

```
In [180]: %%bash

source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont
bcftools view -r chr20:157920-157940 \
    results/03_clair3/HG002.chr20.norm.vcf.gz

bcftools view -r chr20:157920-157940 \
    results/03_clair3/benchmark/HG002_GRCh38_v4.2.1.chr20.refchecked.vcf.gz
```

```

##fileformat=VCFv4.2
##FILTER=<ID=PASS,Description="All filters passed">
##source=Clair3
##clair3_version=2.0.3
##cmdline=/opt/bin/run_clair3.py --bam_fn=/data/results/02_alignment/HG002.chr2
0.bam --ref_fn=/data/data/reference/GRCh38.chr20.fa --threads=4 --platform=ont -
-model_path=/data/config/clair3_models/r1041_e82_400bps_sup_v420 --output=/data/
results/03_clair3 --bed_fn=/data/config/target.chr20.bed --sample_name=HG002_CHR
20
##reference=/data/data/reference/GRCh38.chr20.fa
##FILTER=<ID=LowQual,Description="Low quality variant">
##FILTER=<ID=RefCall,Description="Reference call">
##INFO=<ID=P,Number=0,Type=Flag,Description="Result from pileup calling">
##INFO=<ID=F,Number=0,Type=Flag,Description="Result from full-alignment callin
g">
##FORMAT=<ID=GT,Number=1,Type=String,Description="Genotype">
##FORMAT=<ID=GQ,Number=1,Type=Integer,Description="Genotype Quality">
##FORMAT=<ID=DP,Number=1,Type=Integer,Description="Approximate read depth (reads
1. with MQ below 5 or an user-specified threshold, or 2. selected by 'samtools v
iew -F 2316', are filtered)">
##FORMAT=<ID=AD,Number=R,Type=Integer,Description="Allelic depths for the ref an
d alt alleles in the order listed">
##FORMAT=<ID=PL,Number=G,Type=Integer,Description="Normalized, Phred-scaled like
lihoods for genotypes as defined in the VCF specification">
##FORMAT=<ID=AF,Number=A,Type=Float,Description="Observed allele frequency in re
ads, for each ALT allele, in the same order as listed, or the REF allele for a R
efCall">
##contig=<ID=chr20,length=64444167>
##bcftools_normVersion=1.24+htslib-1.24
##bcftools_normCommand=norm -f data/reference/GRCh38.chr20.fa -m -any -Oz -o res
ults/03_clair3/HG002.chr20.norm.vcf.gz results/03_clair3/merge_output.vcf.gz; Da
te=Thu Sep 24 17:10:46 2026
##bcftools_viewVersion=1.24+htslib-1.24
##bcftools_viewCommand=view -r chr20:157920-157940 results/03_clair3/HG002.chr2
0.norm.vcf.gz; Date=Thu Sep 24 17:11:32 2026
#CHROM POS ID REF ALT QUAL FILTER INFO FORMAT HG002_CH
R20
chr20 157927 . ATATATGTG A 2.69 PASS F GT:GQ:D
P:AD:AF 0/1:2:80:39,26:0.325
chr20 157929 . ATATGTGTG A 0 LowQual F GT:GQ:D
P:AD:AF 0/1:0:80:2,28:0.35
##fileformat=VCFv4.2
##FILTER=<ID=PASS,Description="All filters passed">
##fileDate=20160824
##CL=vcffilter -i - -o - --javascript "function record() {HG002.PS=\".\\\";}"
##contig=<ID=chr1,length=248956422,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr2,length=242193529,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr3,length=198295559,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr4,length=190214555,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr5,length=181538259,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr6,length=170805979,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr7,length=159345973,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr8,length=145138636,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>

```

```
##contig=<ID=chr9,length=138394717,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr10,length=133797422,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr11,length=135086622,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr12,length=133275309,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr13,length=114364328,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr14,length=107043718,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr15,length=101991189,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr16,length=90338345,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr17,length=83257441,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr18,length=80373285,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr19,length=58617616,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr20,length=64444167,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr21,length=46709983,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chr22,length=50818468,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chrX,length=156040895,assembly=human_GRCh38_no_alt_analysis_set.fas
ta>
##contig=<ID=chrY,length=57227415,assembly=human_GRCh38_no_alt_analysis_set.fast
a>
##contig=<ID=chrM,length=16569,assembly=human_GRCh38_no_alt_analysis_set.fasta>
##contig=<ID=chr1_KI270706v1_random,length=175055,assembly=human_GRCh38_no_alt_a
nalysis_set.fasta>
##contig=<ID=chr1_KI270707v1_random,length=32032,assembly=human_GRCh38_no_alt_an
alysis_set.fasta>
##contig=<ID=chr1_KI270708v1_random,length=127682,assembly=human_GRCh38_no_alt_a
nalysis_set.fasta>
##contig=<ID=chr1_KI270709v1_random,length=66860,assembly=human_GRCh38_no_alt_an
alysis_set.fasta>
##contig=<ID=chr1_KI270710v1_random,length=40176,assembly=human_GRCh38_no_alt_an
alysis_set.fasta>
##contig=<ID=chr1_KI270711v1_random,length=42210,assembly=human_GRCh38_no_alt_an
alysis_set.fasta>
##contig=<ID=chr1_KI270712v1_random,length=176043,assembly=human_GRCh38_no_alt_a
nalysis_set.fasta>
##contig=<ID=chr1_KI270713v1_random,length=40745,assembly=human_GRCh38_no_alt_an
alysis_set.fasta>
##contig=<ID=chr1_KI270714v1_random,length=41717,assembly=human_GRCh38_no_alt_an
alysis_set.fasta>
##contig=<ID=chr2_KI270715v1_random,length=161471,assembly=human_GRCh38_no_alt_a
nalysis_set.fasta>
##contig=<ID=chr2_KI270716v1_random,length=153799,assembly=human_GRCh38_no_alt_a
nalysis_set.fasta>
##contig=<ID=chr3_GL000221v1_random,length=155397,assembly=human_GRCh38_no_alt_a
nalysis_set.fasta>
##contig=<ID=chr4_GL000008v2_random,length=209709,assembly=human_GRCh38_no_alt_a
nalysis_set.fasta>
##contig=<ID=chr5_GL000208v1_random,length=92689,assembly=human_GRCh38_no_alt_an
alysis_set.fasta>
##contig=<ID=chr9_KI270717v1_random,length=40062,assembly=human_GRCh38_no_alt_an
```

```
analysis_set.fasta>
##contig=<ID=chr9_KI270718v1_random,length=38054,assembly=human_GRCh38_no_alt_an
alysis_set.fasta>
##contig=<ID=chr9_KI270719v1_random,length=176845,assembly=human_GRCh38_no_alt_a
nalysis_set.fasta>
##contig=<ID=chr9_KI270720v1_random,length=39050,assembly=human_GRCh38_no_alt_an
alysis_set.fasta>
##contig=<ID=chr11_KI270721v1_random,length=100316,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr14_GL000009v2_random,length=201709,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr14_GL000225v1_random,length=211173,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr14_KI270722v1_random,length=194050,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr14_GL000194v1_random,length=191469,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr14_KI270723v1_random,length=38115,assembly=human_GRCh38_no_alt_a
nalysis_set.fasta>
##contig=<ID=chr14_KI270724v1_random,length=39555,assembly=human_GRCh38_no_alt_a
nalysis_set.fasta>
##contig=<ID=chr14_KI270725v1_random,length=172810,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr14_KI270726v1_random,length=43739,assembly=human_GRCh38_no_alt_a
nalysis_set.fasta>
##contig=<ID=chr15_KI270727v1_random,length=448248,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr16_KI270728v1_random,length=1872759,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr17_GL000205v2_random,length=185591,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr17_KI270729v1_random,length=280839,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr17_KI270730v1_random,length=112551,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr22_KI270731v1_random,length=150754,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr22_KI270732v1_random,length=41543,assembly=human_GRCh38_no_alt_a
nalysis_set.fasta>
##contig=<ID=chr22_KI270733v1_random,length=179772,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr22_KI270734v1_random,length=165050,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr22_KI270735v1_random,length=42811,assembly=human_GRCh38_no_alt_a
nalysis_set.fasta>
##contig=<ID=chr22_KI270736v1_random,length=181920,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr22_KI270737v1_random,length=103838,assembly=human_GRCh38_no_alt_
analysis_set.fasta>
##contig=<ID=chr22_KI270738v1_random,length=99375,assembly=human_GRCh38_no_alt_a
nalysis_set.fasta>
##contig=<ID=chr22_KI270739v1_random,length=73985,assembly=human_GRCh38_no_alt_a
nalysis_set.fasta>
##contig=<ID=chrY_KI270740v1_random,length=37240,assembly=human_GRCh38_no_alt_an
alysis_set.fasta>
##contig=<ID=chrUn_KI270302v1,length=2274,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270304v1,length=2165,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270303v1,length=1942,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270305v1,length=1472,assembly=human_GRCh38_no_alt_analysis_
```

```
set.fasta>
##contig=<ID=chrUn_KI270322v1,length=21476,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270320v1,length=4416,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270310v1,length=1201,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270316v1,length=1444,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270315v1,length=2276,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270312v1,length=998,assembly=human_GRCh38_no_alt_analysis_s
et.fasta>
##contig=<ID=chrUn_KI270311v1,length=12399,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270317v1,length=37690,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270412v1,length=1179,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270411v1,length=2646,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270414v1,length=2489,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270419v1,length=1029,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270418v1,length=2145,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270420v1,length=2321,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270424v1,length=2140,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270417v1,length=2043,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270422v1,length=1445,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270423v1,length=981,assembly=human_GRCh38_no_alt_analysis_s
et.fasta>
##contig=<ID=chrUn_KI270425v1,length=1884,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270429v1,length=1361,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270442v1,length=392061,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_KI270466v1,length=1233,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270465v1,length=1774,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270467v1,length=3920,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270435v1,length=92983,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270438v1,length=112505,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_KI270468v1,length=4055,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270510v1,length=2415,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270509v1,length=2318,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270518v1,length=2186,assembly=human_GRCh38_no_alt_analysis_
_set.fasta>
##contig=<ID=chrUn_KI270508v1,length=1951,assembly=human_GRCh38_no_alt_analysis_
```

```
set.fasta>
##contig=<ID=chrUn_KI270516v1,length=1300,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270512v1,length=22689,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270519v1,length=138126,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_KI270522v1,length=5674,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270511v1,length=8127,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270515v1,length=6361,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270507v1,length=5353,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270517v1,length=3253,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270529v1,length=1899,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270528v1,length=2983,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270530v1,length=2168,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270539v1,length=993,assembly=human_GRCh38_no_alt_analysis_s
et.fasta>
##contig=<ID=chrUn_KI270538v1,length=91309,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270544v1,length=1202,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270548v1,length=1599,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270583v1,length=1400,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270587v1,length=2969,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270580v1,length=1553,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270581v1,length=7046,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270579v1,length=31033,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270589v1,length=44474,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270590v1,length=4685,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270584v1,length=4513,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270582v1,length=6504,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270588v1,length=6158,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270593v1,length=3041,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270591v1,length=5796,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270330v1,length=1652,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270329v1,length=1040,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270334v1,length=1368,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270333v1,length=2699,assembly=human_GRCh38_no_alt_analysis_
```

```
set.fasta>
##contig=<ID=chrUn_KI270335v1,length=1048,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270338v1,length=1428,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270340v1,length=1428,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270336v1,length=1026,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270337v1,length=1121,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270363v1,length=1803,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270364v1,length=2855,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270362v1,length=3530,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270366v1,length=8320,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270378v1,length=1048,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270379v1,length=1045,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270389v1,length=1298,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270390v1,length=2387,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270387v1,length=1537,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270395v1,length=1143,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270396v1,length=1880,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270388v1,length=1216,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270394v1,length=970,assembly=human_GRCh38_no_alt_analysis_s
et.fasta>
##contig=<ID=chrUn_KI270386v1,length=1788,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270391v1,length=1484,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270383v1,length=1750,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270393v1,length=1308,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270384v1,length=1658,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270392v1,length=971,assembly=human_GRCh38_no_alt_analysis_s
et.fasta>
##contig=<ID=chrUn_KI270381v1,length=1930,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270385v1,length=990,assembly=human_GRCh38_no_alt_analysis_s
et.fasta>
##contig=<ID=chrUn_KI270382v1,length=4215,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270376v1,length=1136,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270374v1,length=2656,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270372v1,length=1650,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270373v1,length=1451,assembly=human_GRCh38_no_alt_analysis_
```

```
set.fasta>
##contig=<ID=chrUn_KI270375v1,length=2378,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270371v1,length=2805,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270448v1,length=7992,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_KI270521v1,length=7642,assembly=human_GRCh38_no_alt_analysis_
set.fasta>
##contig=<ID=chrUn_GL000195v1,length=182896,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_GL000219v1,length=179198,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_GL000220v1,length=161802,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_GL000224v1,length=179693,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_KI270741v1,length=157432,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_GL000226v1,length=15008,assembly=human_GRCh38_no_alt_analysis
_set.fasta>
##contig=<ID=chrUn_GL000213v1,length=164239,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_KI270743v1,length=210658,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_KI270744v1,length=168472,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_KI270745v1,length=41891,assembly=human_GRCh38_no_alt_analysis
_set.fasta>
##contig=<ID=chrUn_KI270746v1,length=66486,assembly=human_GRCh38_no_alt_analysis
_set.fasta>
##contig=<ID=chrUn_KI270747v1,length=198735,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_KI270748v1,length=93321,assembly=human_GRCh38_no_alt_analysis
_set.fasta>
##contig=<ID=chrUn_KI270749v1,length=158759,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_KI270750v1,length=148850,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_KI270751v1,length=150742,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_KI270752v1,length=27745,assembly=human_GRCh38_no_alt_analysis
_set.fasta>
##contig=<ID=chrUn_KI270753v1,length=62944,assembly=human_GRCh38_no_alt_analysis
_set.fasta>
##contig=<ID=chrUn_KI270754v1,length=40191,assembly=human_GRCh38_no_alt_analysis
_set.fasta>
##contig=<ID=chrUn_KI270755v1,length=36723,assembly=human_GRCh38_no_alt_analysis
_set.fasta>
##contig=<ID=chrUn_KI270756v1,length=79590,assembly=human_GRCh38_no_alt_analysis
_set.fasta>
##contig=<ID=chrUn_KI270757v1,length=71251,assembly=human_GRCh38_no_alt_analysis
_set.fasta>
##contig=<ID=chrUn_GL000214v1,length=137718,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_KI270742v1,length=186739,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_GL000216v2,length=176608,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrUn_GL000218v1,length=161147,assembly=human_GRCh38_no_alt_analysi
s_set.fasta>
##contig=<ID=chrEBV,length=171823,assembly=human_GRCh38_no_alt_analysis_set.fast
```

```

a>
##FILTER=<ID=GQlessthan70,Description="Sum of GQ for datasets with this genotype
less than 70">
##FILTER=<ID=allfilteredandddisagree,Description="All callsets have this call fil
tered or outside the callable regions and they have discordant genotypes or vari
ant calls">
##FILTER=<ID=allfilteredbutagree,Description="All callsets have this call filter
ed or outside the callable regions but they have the same genotype">
##FILTER=<ID=discordantunfiltered,Description="Callsets with unfiltered calls ha
ve discordant genotypes or variant calls">
##FILTER=<ID=discordanthet,Description="Filtered calls where a passing call is h
et and a high GQ but filtered call is hom var, since often the het is wrong">
##FILTER=<ID=questionableindel,Description="Filtered calls where some callsets h
ave a filtered indel larger than 10bp and another dataset has an implied homozyg
ous reference call">
##FILTER=<ID=cgonly,Description="Filtered calls where only Complete Genomics had
this call and it was completely missing from any other callset">
##FILTER=<ID=alleleimbalance,Description="Filtered calls where the net allele ba
lance for unfiltered datasets is <0.2 or >0.8">
##FILTER=<ID=overlappingcall,Description="Filtered sites that are within 50bp of
another passing call but none of the callsets that support the 2 calls match">
##INFO=<ID=DPsum,Number=1,Type=Integer,Description="Total read depth summed acro
ss all datasets, excluding MQ0 reads">
##INFO=<ID=platforms,Number=1,Type=Integer,Description="Number of different plat
forms for which at least one callset called this genotype, whether filtered or n
ot">
##INFO=<ID=platformnames,Number=.,Type=String,Description="Names of platforms fo
r which at least one callset called this genotype, whether filtered or not">
##INFO=<ID=platformbias,Number=.,Type=String,Description="Names of platforms tha
t have reads containing a variant at this location, but the high-confidence call
is homozygous reference, indicating that there is a potential bias.">
##INFO=<ID=datasets,Number=1,Type=Integer,Description="Number of different datas
ets for which at least one callset called this genotype, whether filtered or no
t">
##INFO=<ID=datasetnames,Number=.,Type=String,Description="Names of datasets for
which at least one callset called this genotype, whether filtered or not">
##INFO=<ID=datasetsmissingcall,Number=.,Type=String,Description="Names of datase
ts that are missing a call or have an incorrect call at this location, and the h
igh-confidence call is a variant">
##INFO=<ID=callsets,Number=1,Type=Integer,Description="Number of different calls
ets that called this genotype, whether filtered or not">
##INFO=<ID=callsetnames,Number=.,Type=String,Description="Names of callsets that
called this genotype, whether filtered or not">
##INFO=<ID=varType,Number=1,Type=String,Description="Type of variant">
##INFO=<ID=filt,Number=.,Type=String,Description="List of callsets that had this
call filtered.">
##INFO=<ID=callable,Number=.,Type=String,Description="List of callsets that had
this call in a region with low coverage of high MQ reads.">
##INFO=<ID=difficultregion,Number=.,Type=String,Description="List of difficult r
egion bed files containing this call.">
##INFO=<ID=arbitrated,Number=1,Type=String,Description="TRUE if callsets had dis
cordant calls so that arbitration was needed.">
##INFO=<ID=callsetwiththisuniggenopassing,Number=.,Type=String,Description="Call
set that uniquely calls the PASSing genotype in GT when 2+ PASSing callsets supp
ort a different genotype.">
##INFO=<ID=callsetwithotheruniggenopassing,Number=.,Type=String,Description="Cal
lset that uniquely calls a PASSing genotype different from GT when 2+ PASSing ca
llsets support the genotype in GT.">
##FORMAT=<ID=DP,Number=1,Type=Integer,Description="Total read depth summed acros
s all datasets, excluding MQ0 reads">
##FORMAT=<ID=GQ,Number=1,Type=Integer,Description="Net Genotype quality across a
ll datasets, calculated from GQ scores of callsets supporting the consensus GT,

```

```

using only one callset from each dataset">
##FORMAT=<ID=ADALL,Number=R,Type=Integer,Description="Net allele depths across a
ll datasets">
##FORMAT=<ID=AD,Number=R,Type=Integer,Description="Net allele depths across all
unfiltered datasets with called genotype">
##FORMAT=<ID=GT,Number=1,Type=String,Description="Consensus Genotype across all
datasets with called genotype">
##FORMAT=<ID=PS,Number=1,Type=Integer,Description="Phase set in which this varia
nt falls">
##bcftools_normVersion=1.24+htslib-1.24
##bcftools_normCommand=norm -f data/reference/GRCh38.chr20.fa -c e -r chr20 -Oz
-o results/03_clair3/benchmark/HG002_GRCh38_v4.2.1.chr20.refchecked.vcf.gz data/
reference/giab/HG002_v4.2.1_GRCh38/HG002_GRCh38_1_22_v4.2.1_benchmark.vcf.gz; Da
te=Thu Sep 24 17:11:22 2026
##bcftools_viewVersion=1.24+htslib-1.24
##bcftools_viewCommand=view -r chr20:157920-157940 results/03_clair3/benchmark/H
G002_GRCh38_v4.2.1.chr20.refchecked.vcf.gz; Date=Thu Sep 24 17:11:32 2026
#CHROM POS ID REF ALT QUAL FILTER INFO FORMAT HG002
chr20 157929 . ATATGTGTG A 50 PASS platforms=3;plat
formnames=Illumina,PacBio,10X;datasets=5;datasetnames=HiSeqPE300x,CCS15kb_20kb,H
iSeq250x250,10XChromiumLR,HiSeqMatePair;callsets=5;callsetnames=HiSeqPE300xSenti
eon,CCS15kb_20kbDV,HiSeq250x250Sentieon,10XLRGATK,HiSeqMatePairSentieon;datasets
missingcall=CCS15kb_20kb,CGnormal,HiSeqPE300x,HiSeq250x250,HiSeqMatePair,IonExom
e,SolidSE75bp;callable=CS_HiSeqPE300xSentieon_callable,CS_CCS15kb_20kbDV_callabl
e,CS_HiSeq250x250Sentieon_callable;filt=CS_CCS15kb_20kbDV_filt,CS_CGnormal_filt,
CS_HiSeqPE300xfreebayes_filt,CS_HiSeq250x250Sentieon_filt,CS_HiSeq250x250freebay
es_filt,CS_HiSeqMatePairfreebayes_filt;difficultregion=GRCh38_AllTandemRepeats_1
t51bp_slop5 GT:PS:DP:ADALL:AD:GQ 0/1::505:145,178:122,133:428

```

Liệt kê output:

In [181]:

```

%%bash
source "$((conda info --base)/etc/profile.d/conda.sh"
conda activate ont

ls -lh results/03_clair3/benchmark/clair3_HG002_chr20_happy.*

-rw-r--r-- 1 lamnguyen staff 15K Sep 24 17:11 results/03_clair3/benchmark/c
lair3_HG002_chr20_happy.extended.csv
-rw-r--r-- 1 lamnguyen staff 14K Sep 24 17:11 results/03_clair3/benchmark/c
lair3_HG002_chr20_happy.metrics.json.gz
-rw-r--r-- 1 lamnguyen staff 1.1K Sep 24 17:11 results/03_clair3/benchmark/c
lair3_HG002_chr20_happy.roc.Locations.INDEL.PASS.csv.gz
-rw-r--r-- 1 lamnguyen staff 1.1K Sep 24 17:11 results/03_clair3/benchmark/c
lair3_HG002_chr20_happy.roc.Locations.INDEL.csv.gz
-rw-r--r-- 1 lamnguyen staff 1.6K Sep 24 17:11 results/03_clair3/benchmark/c
lair3_HG002_chr20_happy.roc.Locations.SNP.PASS.csv.gz
-rw-r--r-- 1 lamnguyen staff 1.6K Sep 24 17:11 results/03_clair3/benchmark/c
lair3_HG002_chr20_happy.roc.Locations.SNP.csv.gz
-rw-r--r-- 1 lamnguyen staff 6.7K Sep 24 17:11 results/03_clair3/benchmark/c
lair3_HG002_chr20_happy.roc.all.csv.gz
-rw-r--r-- 1 lamnguyen staff 3.5K Sep 24 17:11 results/03_clair3/benchmark/c
lair3_HG002_chr20_happy.runinfo.json
-rw-r--r-- 1 lamnguyen staff 739B Sep 24 17:11 results/03_clair3/benchmark/c
lair3_HG002_chr20_happy.summary.csv
-rw-r--r-- 1 lamnguyen staff 12K Sep 24 17:11 results/03_clair3/benchmark/c
lair3_HG002_chr20_happy.vcf.gz
-rw-r--r-- 1 lamnguyen staff 253B Sep 24 17:11 results/03_clair3/benchmark/c
lair3_HG002_chr20_happy.vcf.gz.tbi

```

Kiểm tra summary:

```
In [182]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

test -s results/03_clair3/benchmark/clair3_HG002_chr20_happy.summary.csv \
    && echo "hap.py summary: OK"

hap.py summary: OK
```

Kiểm tra annotated VCF:

```
In [183]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

gzip -t results/03_clair3/benchmark/clair3_HG002_chr20_happy.vcf.gz \
    && echo "hap.py annotated VCF: OK"

hap.py annotated VCF: OK
```

Các output thường gặp:

File	Nội dung
*.summary.csv	Metrics tổng hợp SNP và INDEL
*.extended.csv	Metrics chi tiết theo subtype/filter/genotype/subset
*.vcf.gz	Truth và query đã được so sánh, có annotation TP/FP/FN/UNK
.roc/.csv	Dữ liệu precision/recall theo quality threshold khi có thể tạo ROC

59. Đọc summary.csv

Xem toàn bộ summary:

```
In [184]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

column -s, -t \
  < results/03_clair3/benchmark/clair3_HG002_chr20_happy.summary.csv \
  | less -S
```


Type	Filter	TRUTH.TOTAL	TRUTH.TP	TRUTH.FN	QUERY.TOTAL	QUERY.FP	QUERY.UNK
FP.gt	FP.al	METRIC.Recall	METRIC.Precision		METRIC.Frac_NA		METRIC.F1
Score	TRUTH.TOTAL.TiTv_ratio	QUERY.TOTAL.TiTv_ratio	TRUTH.TOTAL.het_hom_ratio		QUERY.TOTAL.het_hom_ratio		
INDEL	ALL	65	59	6	62	3	0
0	3	0.907692	0.9516129999999999		0.0	0.929134	
1.7826086956521738		1.8181818181818181					
INDEL	PASS	65	58	7	60	2	0
0	2	0.892308	0.966667		0.0	0.928	
1.7826086956521738		1.7272727272727273					
SNP	ALL	449	448	1	450	1	0
1	0	0.9977729999999999	0.997778		0.0	0.997775	
2.427480916030534		2.435114503816794		3.4019607843137254		3.455	
4455445544554							
SNP	PASS	449	448	1	449	0	0
0	0	0.9977729999999999	1.0		0.0	0.998885	
2.427480916030534		2.427480916030534		3.4019607843137254		3.445	
5445544554455							

Các cột quan trọng:

Cột	Ý nghĩa
Type	SNP hoặc INDEL
Filter	Thường xem dòng PASS cho callset đã lọc
TRUTH.TOTAL	Tổng truth variants thuộc phạm vi đánh giá
TRUTH.TP	Truth variants khớp query
TRUTH.FN	Truth variants bị query bỏ sót/không khớp
QUERY.TOTAL	Tổng query calls thuộc nhóm đang xét
QUERY.TP	Query calls khớp truth
QUERY.FP	Query calls không khớp truth trong confident region
QUERY.UNK	Query calls không được đánh giá
METRIC.Recall	$TRUTH.TP / (TRUTH.TP + TRUTH.FN)$
METRIC.Precision	$QUERY.TP / (QUERY.TP + QUERY.FP)$
METRIC.F1_Score	Trung bình điều hòa precision và recall
METRIC.Frac_NA	Tỷ lệ query calls không được đánh giá

TRUTH.TP và QUERY.TP có thể khác nhau trong complex regions vì truth và query có thể dùng số record khác nhau để biểu diễn cùng haplotype.

Cách hiểu theo sơ đồ



Filtering tạo ra trade-off:

	ALL	PASS
Recall	92.31%	89.23% ↓
Precision	95.24%	98.31% ↑
F1	93.75%	93.55% ↓ nhẹ

60. Không dùng số record thô để tự tính metric nếu hap.py đã cung cấp metric

Không nên giả định:

```
TRUTH.TP = QUERY.TP
```

Trong trường hợp representation phức tạp:

- một truth record có thể tương ứng nhiều query records;
- nhiều truth records có thể tương ứng một query record;
- hap.py đánh giá haplotype rồi lượng hóa theo representation.

Vì vậy:

- recall dùng `TRUTH.TP` và `TRUTH.FN` ;
- precision dùng `QUERY.TP` và `QUERY.FP` ;
- ưu tiên các cột `METRIC.*` do hap.py xuất.

61. Đọc annotated comparison VCF

Xem sample columns:

In [185]:

```
%%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont
```

```
bcftools query -l \
    results/03_clair3/benchmark/clair3_HG002_chr20_happy.vcf.gz
```

```
[W::bcf_hdr_register_hrec] The definition of Flag "INFO/IMPORT_FAIL" is invalid,
forcing Number=0
```

```
[W::bcf_hdr_check_sanity] AD should be declared as Number=R
```

```
[W::bcf_hdr_check_sanity] GQ should be declared as Type=Integer
```

```
TRUTH
```

```
QUERY
```

Thông thường annotated VCF chứa hai sample columns:

```
TRUTH
```

```
QUERY
```

Xem định nghĩa benchmarking tags:

```
In [186]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools view -h \
  results/03_clair3/benchmark/clair3_HG002_chr20_happy.vcf.gz \
  | grep -E 'ID=(BD|BK|BI|BVT|BLT|QQ)'
```

[W::bcf_hdr_register_hrec] The definition of Flag "INFO/IMPORT_FAIL" is invalid, forcing Number=0
[W::bcf_hdr_check_sanity] AD should be declared as Number=R
[W::bcf_hdr_check_sanity] GQ should be declared as Type=Integer

##FORMAT=<ID=BD,Number=1,Type=String,Description="Decision for call (TP/FP/FN/N)">
##FORMAT=<ID=BK,Number=1,Type=String,Description="Sub-type for decision (match/mismatch type)">
##FORMAT=<ID=BI,Number=1,Type=String,Description="Additional comparison information">
##FORMAT=<ID=QQ,Number=1,Type=Float,Description="Variant quality for ROC creation.">
##FORMAT=<ID=BVT,Number=1,Type=String,Description="High-level variant type (SNP|INDEL).">
##FORMAT=<ID=BLT,Number=1,Type=String,Description="High-level location type (het|homref|hetal|homa|nocall).">

Xuất quyết định của từng sample:

```
In [187]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools query \
  -f '%CHROM\t%POS\t%REF\t%ALT[\t%SAMPLE:%BD:%BK]\n' \
  results/03_clair3/benchmark/clair3_HG002_chr20_happy.vcf.gz \
  | head
```

[W::bcf_hdr_register_hrec] The definition of Flag "INFO/IMPORT_FAIL" is invalid, forcing Number=0
[W::bcf_hdr_check_sanity] AD should be declared as Number=R
[W::bcf_hdr_check_sanity] GQ should be declared as Type=Integer

chr20	85259	G	A	TRUTH:TP:gm	QUERY:TP:gm
chr20	85729	G	A	TRUTH:TP:gm	QUERY:TP:gm
chr20	86859	T	TTGGTATCTAG	TRUTH:TP:gm	QUERY:TP:gm
chr20	88108	T	C	TRUTH:TP:gm	QUERY:TP:gm
chr20	91463	TA	T	TRUTH:TP:gm	QUERY:TP:gm
chr20	92969	CTT	C	TRUTH:TP:gm	QUERY:TP:gm
chr20	94088	G	GT	TRUTH:TP:gm	QUERY:TP:gm
chr20	94613	C	A	TRUTH:TP:gm	QUERY:TP:gm
chr20	96321	T	C	TRUTH:TP:gm	QUERY:TP:gm
chr20	97324	G	GT	TRUTH:TP:gm	QUERY:TP:gm

Các giá trị BD thường cho biết quyết định benchmark như:

- TP ;
- FP ;
- FN ;
- N /no-call;
- UNK .

Định nghĩa chính xác phải lấy từ header của file được tạo ra, không học thuộc một danh sách rồi áp dụng cho mọi phiên bản.

62. Tạo danh sách false positives

```
In [188]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools query \
  -f '%CHROM\t%POS\t%REF\t%ALT[\t%SAMPLE:%BD:%BK]\n' \
  results/03_clair3/benchmark/clair3_HG002_chr20_happy.vcf.gz \
  | awk '$0 ~ /QUERY:FP/' \
  > results/03_clair3/benchmark/clair3_HG002_chr20.false_positives.tsv

[W::bcf_hdr_register_hrec] The definition of Flag "INFO/IMPORT_FAIL" is invalid,
forcing Number=0
[W::bcf_hdr_check_sanity] AD should be declared as Number=R
[W::bcf_hdr_check_sanity] GQ should be declared as Type=Integer
```

Kiểm tra:

```
In [189]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

head results/03_clair3/benchmark/clair3_HG002_chr20.false_positives.tsv

chr20    190675    C          CT          TRUTH:...    QUERY:FP:lm
chr20    207202    T          TAA         TRUTH:...    QUERY:FP:lm
chr20    217754    G          A           TRUTH:FN:am   QUERY:FP:am
chr20    240075    C          CAAAA      TRUTH:...    QUERY:FP:lm
```

In [190]:

```
%%bash

bcftools query -l \
    results/03_clair3/benchmark/clair3_HG002_chr20_happy.vcf.gz

bcftools view -h \
    results/03_clair3/benchmark/clair3_HG002_chr20_happy.vcf.gz \
    | grep '^##FORMAT='
```

```
[W::bcf_hdr_register_hrec] The definition of Flag "INFO/IMPORT_FAIL" is invalid,
forcing Number=0
```

```
[W::bcf_hdr_check_sanity] AD should be declared as Number=R
```

```
[W::bcf_hdr_check_sanity] GQ should be declared as Type=Integer
```

TRUTH

QUERY

```
[W::bcf_hdr_register_hrec] The definition of Flag "INFO/IMPORT_FAIL" is invalid,
forcing Number=0
```

```
[W::bcf_hdr_check_sanity] AD should be declared as Number=R
```

```
[W::bcf_hdr_check_sanity] GQ should be declared as Type=Integer
```

```
##FORMAT=<ID=AGT,Number=1,Type=String,Description="Genotypes at ambiguous locati
ons">
```

```
##FORMAT=<ID=GT,Number=1,Type=String,Description="Genotype">
```

```
##FORMAT=<ID=GQ,Number=1,Type=Float,Description="Genotype Quality">
```

```
##FORMAT=<ID=DP,Number=1,Type=Integer,Description="Read Depth">
```

```
##FORMAT=<ID=AD,Number=A,Type=Integer,Description="Allele Depths">
```

```
##FORMAT=<ID=ADO,Number=.,Type=Integer,Description="Summed depth of non-called a
lles.">
```

```
##FORMAT=<ID=ADALL,Number=R,Type=Integer,Description="Net allele depths across a
ll datasets">
```

```
##FORMAT=<ID=AF,Number=A,Type=Float,Description="Observed allele frequency in re
ads, for each ALT allele, in the same order as listed, or the REF allele for a R
efCall">
```

```
##FORMAT=<ID=PL,Number=G,Type=Integer,Description="Normalized, Phred-scaled like
lihoods for genotypes as defined in the VCF specification">
```

```
##FORMAT=<ID=PS,Number=1,Type=Integer,Description="Phase set in which this varia
nt falls">
```

```
##FORMAT=<ID=BD,Number=1,Type=String,Description="Decision for call (TP/FP/FN/
N)">
```

```
##FORMAT=<ID=BK,Number=1,Type=String,Description="Sub-type for decision (match/m
ismatch type)">
```

```
##FORMAT=<ID=BI,Number=1,Type=String,Description="Additional comparison informat
ion">
```

```
##FORMAT=<ID=QQ,Number=1,Type=Float,Description="Variant quality for ROC creatio
n.">
```

```
##FORMAT=<ID=BVT,Number=1,Type=String,Description="High-level variant type (SNP|
INDEL).">
```

```
##FORMAT=<ID=BLT,Number=1,Type=String,Description="High-level location type (het
|homref|hetal|homa|nocall).">
```

```
In [191]: %%bash

bcftools query \
  -f '%CHROM\t%POS\t%REF\t%ALT[\t%SAMPLE:%BD:%BK]\n' \
  results/03_clair3/benchmark/clair3_HG002_chr20_happy.vcf.gz \
  > results/03_clair3/benchmark/clair3_HG002_chr20_happy.tsv

grep "FP" results/03_clair3/benchmark/clair3_HG002_chr20_happy.tsv
```

```
[W::bcf_hdr_register_hrec] The definition of Flag "INFO/IMPORT_FAIL" is invalid,
forcing Number=0
[W::bcf_hdr_check_sanity] AD should be declared as Number=R
[W::bcf_hdr_check_sanity] GQ should be declared as Type=Integer

chr20    190675    C          CT          TRUTH:...    QUERY:FP:lm
chr20    207202    T          TAA         TRUTH:...    QUERY:FP:lm
chr20    217754    G          A           TRUTH:FN:am   QUERY:FP:am
chr20    240075    C          CAAAA       TRUTH:...    QUERY:FP:lm
```

Không gọi tất cả các dòng này là “sequencing error”. Một FP có thể liên quan:

- allele representation;
- genotype mismatch;
- alignment ambiguity;
- homopolymer/low-complexity region;
- insufficient support;
- truth-set limitation;
- target/confident-region boundary.

63. Tạo danh sách false negatives

```
In [192]: %%bash

source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

bcftools query \
  -f '%CHROM\t%POS\t%REF\t%ALT[\t%SAMPLE:%BD:%BK]\n' \
  results/03_clair3/benchmark/clair3_HG002_chr20_happy.vcf.gz \
  | awk '$0 ~ /TRUTH:FN/' \
  > results/03_clair3/benchmark/clair3_HG002_chr20.false_negatives.tsv
```

```
[W::bcf_hdr_register_hrec] The definition of Flag "INFO/IMPORT_FAIL" is invalid,
forcing Number=0
[W::bcf_hdr_check_sanity] AD should be declared as Number=R
[W::bcf_hdr_check_sanity] GQ should be declared as Type=Integer
```

Kiểm tra:

```
In [193]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

head results/03_clair3/benchmark/clair3_HG002_chr20.false_negatives.tsv
```

chr20	190675	C	CTT	TRUTH:FN:lm	QUERY:...
chr20	206175	T	TA	TRUTH:FN:.	QUERY:...
chr20	207202	T	TA	TRUTH:FN:lm	QUERY:...
chr20	214796	CT	C	TRUTH:FN:lm	QUERY:...
chr20	217754	G	A	TRUTH:FN:am	QUERY:FP:am
chr20	240075	C	CAAA	TRUTH:FN:lm	QUERY:...
chr20	310719	A	AT	TRUTH:FN:.	QUERY:...

```
In [194]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate ont

wc -l results/03_clair3/benchmark/clair3_HG002_chr20.false_negatives.tsv
```

```
7 results/03_clair3/benchmark/clair3_HG002_chr20.false_negatives.tsv
```

FN có thể xuất hiện do:

- không đủ coverage;
 - ALT support thấp;
 - alignment không tốt;
 - model không phù hợp;
 - caller/filter bỏ qua call;
 - variant nằm trong sequence context khó;
 - genotype được gọi không khớp.
-

64. Kiểm tra FP và FN trên IGV

Load các file:

1. data/reference/GRCh38.chr20.fa
2. results/02_alignment/HG002.chr20.sorted.bam
3. results/03_clair3/merge_output.vcf.gz
4. results/03_clair3/benchmark/HG002_GRCh38_v4.2.1.chr20.refchecked.vcf.gz
5. results/03_clair3/benchmark/clair3_HG002_chr20_happy.vcf.gz
6. results/03_clair3/benchmark/HG002.chr20.target_giab_confident.bed

Tại mỗi FP/FN, ghi lại:

- variant type;
- genotype truth và query;
- depth;
- read support;
- MAPQ;
- strand/orientation nếu có;
- homopolymer hoặc repeat context;
- soft clipping/supplementary alignments;
- khoảng cách tới biên target/confident BED.

Không thay đổi classification TP/FP/FN chỉ dựa trên dữ liệu khi nhìn IGV. IGV được dùng để tìm nguyên nhân kỹ thuật có thể giải thích lỗi.

BÀI TẬP LUYỆN TẬP

Hãy review hết những FP và FN trong file happy vcf và giải thích tại sao?

TÀI LIỆU THAM KHẢO

1. Clair3 repository và hướng dẫn cài đặt/chạy:
 - <https://github.com/HKU-BAL/Clair3> (<https://github.com/HKU-BAL/Clair3>)
 2. Clair3 ONT quick demo:
 - https://github.com/HKU-BAL/Clair3/blob/main/docs/quick_demo/ont_quick_demo.md (https://github.com/HKU-BAL/Clair3/blob/main/docs/quick_demo/ont_quick_demo.md)
 3. BCFtools manual:
 - <https://samtools.github.io/bcftools/bcftools.html> (<https://samtools.github.io/bcftools/bcftools.html>)
 4. BCFtools query how-to:
 - <https://samtools.github.io/bcftools/howtos/query.html> (<https://samtools.github.io/bcftools/howtos/query.html>)
 5. BCFtools filtering how-to:
 - <https://samtools.github.io/bcftools/howtos/filtering.html> (<https://samtools.github.io/bcftools/howtos/filtering.html>)
 6. VCF specification:
 - <https://samtools.github.io/hts-specs/VCFv4.5.pdf> (<https://samtools.github.io/hts-specs/VCFv4.5.pdf>)
 7. HTS specifications repository:
 - <https://github.com/samtools/hts-specs> (<https://github.com/samtools/hts-specs>)
 8. Genome in a Bottle tại NIST:
 - <https://www.nist.gov/programs-projects/genome-bottle> (<https://www.nist.gov/programs-projects/genome-bottle>)
 9. GIAB latest-release repository:
 - https://github.com/genome-in-a-bottle/giab_latest_release (https://github.com/genome-in-a-bottle/giab_latest_release)
 10. Hap.py repository:
 - <https://github.com/Illumina/hap.py> (<https://github.com/Illumina/hap.py>)
 11. Hap.py user manual:
 - <https://github.com/Illumina/hap.py/blob/master/doc/happy.md> (<https://github.com/Illumina/hap.py/blob/master/doc/happy.md>)
 12. Bioconda recipe cho hap.py:
 - <https://bioconda.github.io/recipes/hap.py/README.html> (<https://bioconda.github.io/recipes/hap.py/README.html>)
-