

BUỔI 6: Variant Annotation + Demo Nextflow

Tổng quan quy trình

```
Dữ liệu sequencing
↓
Basecalling / FASTQ
↓
QC và lọc reads
↓
Alignment với reference → BAM/CRAM và coverage
↓
Variant calling bằng Clair3 → VCF
↓
Chuẩn hóa, lọc và kiểm tra variant
↓
Benchmark với truth set trong confident regions
↓
-> Annotation bằng SnpEff và ClinVar
↓
-> Bảng kết quả, (Demo workflow Nextflow)
```

1. Nội dung

1. Phân biệt variant annotation với variant interpretation.
 2. Dùng SnpEff để dự đoán ảnh hưởng của variant trên transcript và protein.
 3. Đọc trường ANN, EFFECT, IMPACT, HGVS.c và HGVS.p.
 4. Chuẩn hóa ClinVar GRCh38 và ghép theo đúng CHROM+POS+REF+ALT.
 5. Diễn giải CLNSIG, CLNREVSTAT, CLNDN và conflict.
 6. Xuất bảng TSV và xây dựng báo cáo toàn quy trình.
 7. Giải thích Nextflow giúp tự động hóa và tái lập pipeline như thế nào.
 8. Chạy hoặc quan sát demo wf-human-variation trên máy phù hợp.
-

Tổng quan về variant annotation

2. Variant calling, annotation và interpretation

Bước	Câu hỏi chính	Công cụ
Variant calling	Mẫu khác reference ở đâu? Genotype là gì?	Clair3
Functional annotation	Variant có thể ảnh hưởng gene/transcript/protein thế nào?	SnpEff
Clinical annotation	Variant đã được ghi nhận trong cơ sở dữ liệu nào?	ClinVar
Interpretation	Bằng chứng tổng hợp có ý nghĩa gì trong bối cảnh cụ thể?	Quy trình chuyên môn, chuyên gia

3. Thông tin annotation

SnpEff

- Dùng mô hình gene và transcript.
- Dự đoán: `missense_variant` , `synonymous_variant` , `frameshift_variant` .
- Tạo trường `INFO/ANN` trong VCF.

ClinVar

- Là kho lưu trữ các submission về mối liên hệ variant–condition.
- Cung cấp clinical significance, condition và review status.
- Thay đổi theo release; cần ghi ngày tải và checksum.

SnpEff và ClinVar trả lời hai câu hỏi khác nhau, nên dùng kết hợp cả hai để có nhiều thông tin chú giải

Annotation bằng SnpEff

4. Cài đặt môi trường mới

```
In [3]: %%bash

:<< "Chay neu chua cai"
conda create -n annotation \
  -c conda-forge \
  -c bioconda \
  -y \
  snpeff=5.4.0c \
  snpsift=5.4.0c \
  bcftools=1.22 \
  htlib=1.22 \
  samtools=1.22 \
  seqkit \
  mosdepth \
  multiqc \
  pandoc \
  openjdk=21
COMENT

# Activate môi trường
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate annotation
```

5. Download database cho SnpEff

GRCh38.mane.1.2.refseq

Lý do:

- cùng assembly GRCh38 với VCF;
- MANE (Match Annotation from NCBI and EMBL-EBI) giúp giảm số transcript cần diễn giải;
- RefSeq transcript có định danh như NM_... , thường thuận tiện khi đối chiếu tài liệu lâm sàng;

Kiểm tra database cho snpEff

```
In [4]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate annotation
#-----

snpEff databases \
| grep 'GRCh38.mane.1.2'
```

```
GRCh38.mane.1.2.ensembl                                Human genome GRC
h38, using MANE transcripts v1.2, Ensembl IDs
[https://snpeff-public.s3.amazonaws.com/databases/v5_4/snpEff_v5_4_GRCh38.mane.
1.2.ensembl.zip, https://snpeff-public.s3.amazonaws.com/databases/v5_3/snpEff_v5_
3_GRCh38.mane.1.2.ensembl.zip, https://snpeff-public.s3.amazonaws.com/database
s/v5_2/snpEff_v5_2_GRCh38.mane.1.2.ensembl.zip, https://snpeff-public.s3.amazona
ws.com/databases/v5_1/snpEff_v5_1_GRCh38.mane.1.2.ensembl.zip, https://snpeff-pu
blic.s3.amazonaws.com/databases/v5_0/snpEff_v5_0_GRCh38.mane.1.2.ensembl.zip]
GRCh38.mane.1.2.refseq                                Human genome GRC
h38, using MANE transcripts v1.2, RefSeq IDs
[https://snpeff-public.s3.amazonaws.com/databases/v5_4/snpEff_v5_4_GRCh38.mane.
1.2.refseq.zip, https://snpeff-public.s3.amazonaws.com/databases/v5_3/snpEff_v5_
3_GRCh38.mane.1.2.refseq.zip, https://snpeff-public.s3.amazonaws.com/databases/v
5_2/snpEff_v5_2_GRCh38.mane.1.2.refseq.zip, https://snpeff-public.s3.amazonaws.c
om/databases/v5_1/snpEff_v5_1_GRCh38.mane.1.2.refseq.zip, https://snpeff-public.
s3.amazonaws.com/databases/v5_0/snpEff_v5_0_GRCh38.mane.1.2.refseq.zip]
test_GRCh38.mane.1.2.ensembl.chr1                      GRCh38 MANE 1.2
chr1
[https://snpeff-public.s3.amazonaws.com/databases/v5_4/snpEff_v5_4_test_GRCh38.m
ane.1.2.ensembl.chr1.zip, https://snpeff-public.s3.amazonaws.com/databases/v5_3/
snpEff_v5_3_test_GRCh38.mane.1.2.ensembl.chr1.zip, https://snpeff-public.s3.amaz
onaws.com/databases/v5_2/snpEff_v5_2_test_GRCh38.mane.1.2.ensembl.chr1.zip, http
s://snpeff-public.s3.amazonaws.com/databases/v5_1/snpEff_v5_1_test_GRCh38.mane.
1.2.ensembl.chr1.zip, https://snpeff-public.s3.amazonaws.com/databases/v5_0/snpE
ff_v5_0_test_GRCh38.mane.1.2.ensembl.chr1.zip]
```

Download database (refseq)

```
In [50]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate annotation
#-----

snpEff download \
    GRCh38.mane.1.2.refseq
```

6. Chạy SnpEff

```
In [7]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate annotation
#-----

snpEff \
  -Xmx4g \
  -v \
  -stats results/04_annotation/HG002.chr20.snpeff_summary.html \
  GRCh38.mane.1.2.refseq \
  results/03_clair3/HG002.chr20.norm.vcf.gz \
  2> logs/snpeff.HG002.chr20.stderr.log \
  | bgzip -c \
  > results/04_annotation/HG002.chr20.norm.snpeff.vcf.gz

bcftools index -t \
  results/04_annotation/HG002.chr20.norm.snpeff.vcf.gz
```

`-Xmx4g` giới hạn heap Java ở 4 GB. Giá trị này cần phù hợp với RAM thực tế của máy.

7. Cấu trúc trường ANN

Một annotation có 16 trường, phân cách bằng ký tự `|` :

```
Allele | Annotation | Impact | Gene_Name | Gene_ID |
Feature_Type | Feature_ID | Transcript_BioType | Rank |
HGVS.c | HGVS.p | cDNA.pos/length | CDS.pos/length |
AA.pos/length | Distance | Errors/Warnings/Info
```

Một VCF record có thể có nhiều annotation; các annotation được phân cách bằng dấu phẩy.

Do đó:

- một **variant record** không nhất thiết tương ứng một **transcript consequence**;
 - số annotation có thể lớn hơn số variant;
 - không lấy annotation đầu tiên mà không nêu tiêu chí chọn transcript.
-

8. EFFECT : theo Sequence Ontology

Ví dụ thường gặp:

EFFECT	Diễn giải ngắn
synonymous_variant	Codon đổi nhưng amino acid không đổi
missense_variant	Amino acid bị thay đổi
stop_gained	Tạo codon kết thúc sớm
frameshift_variant	Indel làm thay đổi khung đọc
splice_donor_variant	Ảnh hưởng vị trí donor của splice site
intron_variant	Nằm trong intron
upstream_gene_variant	Nằm phía upstream gene theo ngưỡng database
intergenic_region	Nằm ngoài gene model được annotation

Đây là mô tả ảnh hưởng của variant, không phải chẩn đoán bệnh.

9. IMPACT không phải pathogenicity

IMPACT	Ý nghĩa trong SnpEff	Không được kết luận
HIGH	Dự đoán ảnh hưởng mạnh lên cấu trúc/chức năng transcript	Chắc chắn gây bệnh
MODERATE	Có thể làm thay đổi hiệu quả protein	Có ý nghĩa lâm sàng
LOW	Thường ít làm thay đổi protein	Chắc chắn lành tính
MODIFIER	Thường non-coding hoặc khó dự đoán	Không có tác động sinh học

Ví dụ:

```
SnpEff IMPACT=HIGH ≠ ClinVar CLNSIG=Pathogenic
SnpEff IMPACT=MODIFIER ≠ ClinVar CLNSIG=Benign
```

10. HGVS .c , HGVS .p và transcript

- HGVS .c : mô tả thay đổi trên transcript DNA/coding sequence.
- HGVS .p : mô tả hậu quả dự đoán trên protein.
- FEATURE_ID : transcript được dùng để tạo HGVS.

Ví dụ khái niệm:

```
NM_000000.1:c.100G>A
NP_000000.1:p.Gly34Arg
```

Không báo cáo riêng c.100G>A hoặc p.Gly34Arg mà bỏ transcript. Một genomic variant có thể có HGVS khác nhau trên các transcript khác nhau.

11. Đọc báo cáo HTML của SnpEff

Mở file:

```
results/04_annotation/HG002.chr20.snpeff_summary.html
```

Các mục nên xem:

- số variant được xử lý;
- phân bố variant type;
- phân bố effect và impact;
- số warning/error;
- transition/transversion nếu report có cung cấp;
- phân bố theo vùng gene.

Không dùng tổng số effects như tổng số variant, vì một variant có thể tạo nhiều effect theo transcript.

Annotation bằng Clinvar

12. ClinVar là gì?

ClinVar là kho lưu trữ công khai của NCBI về các assertion liên quan giữa variant và phenotype/condition.

ClinVar có thể chứa:

- nhiều submitter cho cùng một variant;
- các classification đồng thuận hoặc mâu thuẫn;
- mức độ review khác nhau;
- thông tin germline, oncogenicity và somatic clinical impact.

ClinVar không tự xác minh độc lập mọi submission và không được dùng một mình để ra quyết định lâm sàng.

13. Tải ClinVar GRCh38

```
In [51]: %%bash
mkdir -p data/reference/clinvar

wget -q \
  -O data/reference/clinvar/clinvar_GRCh38.vcf.gz \
  'https://ftp.ncbi.nlm.nih.gov/pub/clinvar/vcf_GRCh38/clinvar.vcf.gz'

wget -q \
  -O data/reference/clinvar/clinvar_GRCh38.vcf.gz.tbi \
  'https://ftp.ncbi.nlm.nih.gov/pub/clinvar/vcf_GRCh38/clinvar.vcf.gz.tbi'

sha256sum \
  data/reference/clinvar/clinvar_GRCh38.vcf.gz \
  > data/reference/clinvar/clinvar_GRCh38.vcf.gz.sha256
```

ClinVar là database động. Không ghi báo cáo chỉ bằng từ “latest”; phải lưu release date và checksum (Nếu có)

14. Kiểm tra VCF

```
In [52]: %%bash
bcftools view -h \
  data/reference/clinvar/clinvar_GRCh38.vcf.gz \
  | grep -E '^##fileDate|^##reference|^##contig' \
  | head -n 3

bcftools index -s \
  data/reference/clinvar/clinvar_GRCh38.vcf.gz \
  | head -n 3

bcftools view -h \
  data/reference/clinvar/clinvar_GRCh38.vcf.gz \
  | grep '^##fileDate=' \
  > data/reference/clinvar/clinvar_GRCh38.release.txt

##fileDate=2026-09-28
##reference=GRCh38
##contig=<ID=1>
1      .      411801
2      .      397012
3      .      248887
```

Điểm cần xác nhận:

- assembly là GRCh38;
- ClinVar dùng 20 hay chr20 ;
- index tương ứng đúng file VCF vừa tải.

15. Vì sao 20 và chr20 quan trọng?

Trong khóa học:

Query VCF: chr20
ClinVar: thường là 20

Phần mềm xem 20 và chr20 là hai tên contig khác nhau nếu không có bước đổi tên.

Hậu quả khi không xử lý:

- không có ClinVar hit dù allele thật sự tồn tại;
- bcftools báo contig không tồn tại;
- Nextflow hoặc workflow downstream dừng.

Luôn inspect header trước; không đoán convention.

16. Tạo bảng đổi tên chromosome

Chỉ chạy bước sau khi đã xác nhận ClinVar dùng 20 :

```
In [11]: %%bash
printf '20\tchr20\n' \
> config/clinvar_GRCh38_to_course.map

cat config/clinvar_GRCh38_to_course.map

20      chr20
```

Output:

```
20      chr20
```

Nếu ClinVar đã dùng chr20 , không đổi tên và thay -r 20 bằng -r chr20 ở bước tiếp theo.

17. Normalize Chr20 Clinvar VCF

```
In [12]: %%bash
bcftools view \
-r 20 \
data/reference/clinvar/clinvar_GRCh38.vcf.gz \
-Ou \
| bcftools annotate \
--rename-chrs config/clinvar_GRCh38_to_course.map \
-Ou \
| bcftools norm \
-f data/reference/GRCh38.chr20.fa \
-c e \
-m -any \
-Oz \
-o data/reference/clinvar/clinvar_GRCh38.chr20.norm.vcf.gz

bcftools index -t \
data/reference/clinvar/clinvar_GRCh38.chr20.norm.vcf.gz

Lines    total/split/joined/realigned/mismatch_removed/dup_removed/skipped:
98510/0/0/0/0/0/0
```

-c e là stop condition khi REF không khớp.

18. Vì sao phải normalize cả hai VCF?

Cùng một indel có thể có nhiều biểu diễn tương đương trong vùng lặp.

Ví dụ khái niệm:

Position:	100	101	102	103	104
Reference:	A	T	T	T	C
Query VCF:	chr20	102	TT	T	
ClinVar VCF:	chr20	100	AT	A	
After normalize:					
Query VCF:	chr20	100	AT	A	

Nếu chưa left-normalize, hai record có thể mô tả cùng thay đổi sinh học nhưng không khớp theo allele.

Quy trình an toàn:

1. cùng assembly;
2. cùng FASTA;
3. cùng contig naming;
4. left-normalize;
5. split multiallelic;
6. exact match CHROM+POS+REF+ALT .

19. Ghép ClinVar theo exact allele

```
In [13]: %%bash
bcftools annotate \
  --annotations data/reference/clinvar/clinvar_GRCh38.chr20.norm.vcf.gz \
  --pair-logic exact \
  --columns ID,INFO/ALLELEID,INFO/CLNDN,INFO/CLNDISDB,INFO/CLNHGVS,INFO/CLNREVSTA
T,INFO/CLNSIG,INFO/CLNSIGCONF,INFO/CLNVC \
  --output-type z \
  --output results/04_annotation/HG002.chr20.norm.snpeff.clinvar.vcf.gz \
  results/04_annotation/HG002.chr20.norm.snpeff.vcf.gz

bcftools index -t \
  results/04_annotation/HG002.chr20.norm.snpeff.clinvar.vcf.gz
```

ID được lấy từ ClinVar. Nếu cần bảo toàn ID có sẵn của caller, bỏ ID khỏi danh sách --columns .

20. Không annotation theo position-only

Tại cùng một vị trí có thể tồn tại nhiều ALT allele:

```
chr20:1000 G>A
chr20:1000 G>C
```

Hai variant này khác nhau về:

- nucleotide thay thế;
- consequence trên codon;
- tần suất quần thể;
- clinical significance;
- bằng chứng trong ClinVar.

Chỉ khớp `CHROM+POS` có thể gán thông tin của `G>A` cho `G>C`. Vì vậy quy trình dùng exact allele matching.

21. Kiểm tra header ClinVar đã được thêm

```
In [14]: %%bash
bcftools view -h \
  results/04_annotation/HG002.chr20.norm.snpeff.clinvar.vcf.gz \
  | grep -E 'ID=(ANN|ALLELEID|CLNSIG|CLNREVSTAT|CLNDN|CLNSIGCONF)'
```

```
##INFO=<ID=ANN,Number=.,Type=String,Description="Functional annotations: 'Allele
| Annotation | Annotation_Impact | Gene_Name | Gene_ID | Feature_Type | Feature_
ID | Transcript_BioType | Rank | HGVS.c | HGVS.p | cDNA.pos / cDNA.length | CDS.
pos / CDS.length | AA.pos / AA.length | Distance | ERRORS / WARNINGS / INFO'">
##INFO=<ID=ALLELEID,Number=1,Type=Integer,Description="the ClinVar Allele ID">
##INFO=<ID=CLNDN,Number=.,Type=String,Description="ClinVar's preferred disease n
ame for the concept specified by disease identifiers in CLNDISDB">
##INFO=<ID=CLNREVSTAT,Number=.,Type=String,Description="ClinVar review status of
germline classification for the Variation ID">
##INFO=<ID=CLNSIG,Number=.,Type=String,Description="Aggregate germline classific
ation for this single variant; multiple values are separated by a vertical bar">
##INFO=<ID=CLNSIGCONF,Number=.,Type=String,Description="Conflicting germline cla
ssification for this single variant; multiple values are separated by a vertical
bar">
```

Xem các record có ClinVar hit và đếm số lượng:

```
In [42]: %%bash
bcftools query \
-i 'INFO/CLNSIG!="."' \
-f '%CHROM\t%POS\t%REF\t%ALT\t%CLNSIG\t%CLNREVSTAT\t%CLNDN\n' \
results/04_annotation/HG002.chr20.norm.snpeff.clinvar.vcf.gz \
| head

bcftools view \
-H \
-i 'INFO/CLNSIG!="."' \
results/04_annotation/HG002.chr20.norm.snpeff.clinvar.vcf.gz \
| wc -l

chr20    145669    ACC      A          Benign    criteria_provided,_single_submitter
not_specified
1
```

Diễn giải:

Đây là số record có exact allele match và có CLNSIG trong release ClinVar đã tải.

Không diễn giải thành:

Các record còn lại là benign.

Không có hit có thể do variant chưa được submit, không nằm trong export, representation khác, hoặc không có exact allele match.

22. Đọc các trường ClinVar chính

Trường	Ý nghĩa
ALLELEID	ClinVar Allele ID
CLNSIG	Aggregate germline clinical significance
CLNREVSTAT	Review status của aggregate germline assertion
CLNDN	Tên condition/disease được submit
CLNDISDB	Định danh condition trong database liên quan
CLNHGVS	HGVS do ClinVar cung cấp
CLNSIGCONF	Chi tiết classification khi có conflict
CLNVC	Loại variant theo ClinVar

Luôn đọc CLNSIG cùng CLNDN , CLNREVSTAT và release date.

23. Review status và số sao ClinVar

Số sao	Khái quát review status
4	Practice guideline
3	Reviewed by expert panel
2	Aggregate germline/oncogenicity: nhiều submitter, có criteria, classification đồng thuận
1	Aggregate germline/oncogenicity: một submitter có criteria, hoặc nhiều submitter có classification mâu thuẫn
0	Không có assertion criteria, không có classification, hoặc variant không được phân loại riêng mà chỉ xuất hiện trong haplotype/genotype

Các mô tả 2 sao và 1 sao trong bảng áp dụng cho aggregate germline/oncogenicity. Với somatic clinical impact, nhiều mức classification khác nhau không tự động được xem là conflict; xem định nghĩa review status riêng theo loại assertion trên ClinVar.

Số sao phản ánh mức review/minh bạch/đồng thuận theo loại assertion, không phản ánh “độ nặng” của bệnh.

Một classification `Pathogenic` với review thấp không được xem như có mức bằng chứng giống expert panel.

24. Ví dụ diễn giải một record

Giả sử record có:

```
ANN=...|missense_variant|HIGH|GENE1|...|NM_...|...|c.100G>A|p.Gly34Arg|...
CLNSIG=Uncertain_significance
CLNREVSTAT=criteria_provided,_single_submitter
CLNDN=Condition_X
```

Diễn giải phù hợp:

Variant được SnpEff dự đoán là missense trên transcript được chỉ rõ, với IMPACT mức HIGH. Trong release ClinVar được sử dụng, variant có aggregate germline classification là Uncertain significance cho Condition X, với criteria do một submitter cung cấp.

Không nên kết luận:

Variant gây bệnh vì làm thay đổi amino acid.

25. Xuất bảng annotation TSV bằng SnpSift

```
In [49]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate annotation
#-----

SnpSift extractFields \
  -s ',' \
  -e '.' \
  results/04_annotation/HG002.chr20.norm.snpeff.clinvar.vcf.gz \
  CHROM POS ID REF ALT QUAL FILTER \
  'GEN[0].GT' 'GEN[0].GQ' 'GEN[0].DP' 'GEN[0].AD' 'GEN[0].AF' \
  'ANN[*].EFFECT' 'ANN[*].IMPACT' 'ANN[*].GENE' \
  'ANN[*].FEATUREID' 'ANN[*].HGVS_C' 'ANN[*].HGVS_P' \
  CLNSIG CLNREVSTAT CLNSIGCONF CLNDN \
  > results/04_annotation/HG002.chr20.variant_report.tsv

column -t -s $'\t' \
  results/04_annotation/HG002.chr20.variant_report.tsv \
  | head -n 10
```

CHROM	POS	ID	REF	ALT	QUAL	FILTER	GEN[0].GT	GEN[0].GQ	GEN[0].DP	GEN[0].AD	GEN[0].AF	ANN[*].EF
FECT												
ANN[*].IMPACT												
ANN[*].GENE				ANN[*].FEATUREID				ANN				
[*].HGVS_C								ANN				
[*].HGVS_P				CLNSIG	CLNREVSTAT	CLNSIGCONF				CLNDN		
chr20	66235	.	C	CGACT	3.78	PASS	1/1	3	50	4,1	0.02	intergeni
c_region												
CHR_START-DEFB125				CHR_START-DEFB125				n.6623				
5_66236insGACT												
.												
chr20	68303	.	T	C	35.49	PASS	1/1	35	56	0,56	1.0	intergeni
c_region												
CHR_START-DEFB125				CHR_START-DEFB125				n.6830				
3T>C												
.												
chr20	72765	.	T	TA	9.1	PASS	1/1	9	61	11,18	0.2951	intergeni
c_region												
CHR_START-DEFB125				CHR_START-DEFB125				n.7276				
5_72766insA												
.												
chr20	81154	.	T	G	35.26	PASS	1/1	35	83	0,83	1.0	intergeni
c_region												
CHR_START-DEFB125				CHR_START-DEFB125				n.8115				
4T>G												
.												
chr20	85259	.	G	A	30.52	PASS	1/1	30	84	0,83	0.9881	upstream_
gene_variant,intergenic_region												
DEFB125,CHR_START-DEFB125				NM_153325.4,CHR_START-DEFB125				c.-245				
1G>A,n.85259G>A												
...												
chr20	85729	.	G	A	35.45	PASS	1/1	35	83	1,79	0.9518	upstream_
gene_variant,intergenic_region												
DEFB125,CHR_START-DEFB125				NM_153325.4,CHR_START-DEFB125				c.-198				
1G>A,n.85729G>A												
...												
chr20	86859	.	T	TTGGTATCTAG	34.21	PASS	1/1	34	89	2,82	0.9213	upstream_
gene_variant,intergenic_region												
DEFB125,CHR_START-DEFB125				NM_153325.4,CHR_START-DEFB125				c.-851				
_-850insTGGTATCTAG,n.86859_86860insTGGTATCTAG												
...												
chr20	88108	.	T	C	22.07	PASS	0/1	22	96	49,47	0.4896	intron_va
riant												
DEFB125				NM_153325.4				c.58+3				
41T>C												
.												
chr20	91463	.	TA	T	29.03	PASS	1/1	29	107	2,105	0.9813	intron_va
riant												
DEFB125				NM_153325.4				c.58+3				
700delA												
.												

In []:

-s ' , ' nối các giá trị của wildcard ANN[*] bằng dấu phẩy, tránh làm vỡ số cột TSV.

Cảnh báo:

- các trường ANN[*] chứa danh sách song song;
- báo cáo transcript-aware cần giữ đúng quan hệ giữa effect, transcript và HGVS;

26. Bảng annotation mẫu — SnpEff + ClinVar

Xuất bảng variant kèm annotation SnpEff và ClinVar từ
results/04_annotation/HG002.chr20.norm.snpeff.clinvar.vcf.gz :

```
In [41]: %%bash
source "$(conda info --base)/etc/profile.d/conda.sh"
conda activate annotation
#-----

bcftools view -H results/04_annotation/HG002.chr20.norm.snpeff.clinvar.vcf.gz | head -n 1

SnpSift extractFields \
-s ' , ' \
-e ' . ' \
results/04_annotation/HG002.chr20.norm.snpeff.clinvar.vcf.gz \
CHROM POS REF ALT \
'GEN[0].GT' 'GEN[0].AF' \
'ANN[*].EFFECT' 'ANN[*].IMPACT' 'ANN[*].GENE' \
'ANN[*].HGVS_C' 'ANN[*].HGVS_P' \
CLNSIG CLNREVSTAT CLNDN CLNHGVS \
> results/04_annotation/HG002.chr20.snpeff_clinvar_table.tsv

column -t -s $'\t' \
results/04_annotation/HG002.chr20.snpeff_clinvar_table.tsv \
| grep "HIGH" | head -n 5
```

```
chr20    66235    .          C          CGACT    3.78    PASS    F;ANN=CGACT|intergenic_r
egion|MODIFIER|CHR_START-DEFB125|CHR_START-DEFB125|intergenic_region|CHR_START-D
EFB125|||n.66235_66236insGACT|||||GT:GQ:DP:AD:AF    1/1:3:50:4,1:0.02
chr20    145669    ACC          A
1/1          0.875          frameshift_variant
HIGH          DEFB126          c.317_318delCC
p.Pro106fs    Benign    criteria_provided,_single_submitter    not_specified    NC_0
00020.11:g.145673_145674del
```

Cách đọc bảng:

- Record đầu tiên minh họa lại Mục 9: SnpEff dự đoán `IMPACT=HIGH` (frameshift) trong khi ClinVar phân loại `Benign` — hai lớp thông tin không mâu thuẫn nếu đọc đúng ngữ cảnh của từng công cụ.
- `Ô .` là placeholder do `-e '.'` `empty value` khi extract; nó có nghĩa là *không có giá trị*, không phải "được xác nhận là benign" hay "không có ý nghĩa".
- `CLNSIG / CLNDN` trống không đồng nghĩa "loại trừ ý nghĩa lâm sàng"; ClinVar có thể chưa từng nhận submission cho allele đó.

27. Báo cáo toàn quy trình phân tích cần trả lời gì?

1. Dữ liệu là mẫu nào, sequencing platform và reference nào?
2. FASTQ có bao nhiêu read/base, N50 và quality distribution ra sao?
3. Tỷ lệ mapping, MAPQ và coverage trong vùng đích (nếu có) ra sao?
4. Variant calling (Clair3) gọi bao nhiêu SNV/indel và genotype distribution thế nào?
5. Benchmark với GIAB cho precision/recall/F1 nào trong vùng đánh giá? (nếu có)
6. Variant annotation
 - SnpEff dự đoán các consequence nào?
 - Bao nhiêu variant có exact ClinVar hit và review status nào?
7. Hạn chế là gì? nếu có
8. Phiên bản phần mềm, model, database release và checksum?

Demo Nextflow

28. Nextflow giải quyết vấn đề gì?

Nextflow giúp mô tả và thực thi pipeline gồm nhiều process:

- quản lý dependency bằng container/environment;
- truyền file giữa các process;
- chạy song song các task độc lập;
- ghi log và execution metadata;
- cache kết quả để chạy tiếp với `-resume` ;
- tách logic workflow khỏi hạ tầng thực thi.

Demo không thay thế các bước thủ công đã học. Mục tiêu là nhìn thấy cách các bước phân tích được hình thành một workflow có thể tái lập.

29. Workflow wf-human-variation

Workflow chính thức của EPI2ME Labs có thể gồm các nhánh:

- alignment;
- SNP/small-variant calling bằng Clair3;
- structural variants;
- CNV;
- STR;
- modified bases;
- phasing;
- annotation và HTML reports.

Trong demo chỉ bật:

--snp

Vì giới hạn cấu hình máy tính.

30. Điều kiện phần cứng của demo

Theo tài liệu workflow:

Mục	Yêu cầu
Kiến trúc	Linux x86-64; ARM không được hỗ trợ chính thức
CPU tối thiểu	16 CPU
RAM tối thiểu	32 GB
Khuyến nghị	32 CPU, 128 GB RAM
Coverage WGS	tối thiểu khoảng 20x; khuyến nghị trên 30x
Runtime	Docker hoặc Singularity/Apptainer theo profile phù hợp

31. Cài Nextflow và kiểm tra Docker

```
In [ ]: %%bash
mamba create -n nextflow \
  -c conda-forge \
  -c bioconda \
  -y \
  nextflow \
  openjdk=21

conda activate nextflow

nextflow -version
docker --version
```

Nếu `docker info` lỗi quyền hoặc daemon chưa chạy, không khởi động workflow cho tới khi Docker hoạt động đúng.

32. Tải dữ liệu demo (nếu chưa có)

```
In [ ]: %%bash
mkdir -p \
  data/raw/wf_demo \
  results/05_nextflow_demo \
  logs

wget \
  -O data/raw/wf_demo/wf-human-variation-demo.tar.gz \
  'https://ont-exd-int-s3-euwest1-epi2me-labs.s3.amazonaws.com/wf-human-variation/hg002%2bmods.v1/wf-human-variation-demo.tar.gz'

tar -tzf \
  data/raw/wf_demo/wf-human-variation-demo.tar.gz \
  | head

tar -xzf \
  data/raw/wf_demo/wf-human-variation-demo.tar.gz \
  -C data/raw/wf_demo
```

Xem nội dung archive trước khi giải nén giúp xác nhận thư mục top-level và filename thực tế.

33. Chạy demo `wf-human-variation`

Workflow v2.8.1 công bố yêu cầu tối thiểu 16 CPU và 32 GB RAM; cấu hình process với `cpus / memory` thấp hơn không làm giảm đáng tin cậy yêu cầu tổng thể hoặc trở thành cấu hình được hỗ trợ. Dùng máy chủ Linux x86-64 có đủ tài nguyên và Docker hoạt động. Demo dùng BAM đã căn chỉnh nên process căn chỉnh không phải lý do để giảm yêu cầu tài nguyên.

```
In [ ]: %%bash
NXF_SYNTAX_PARSER=v1 nextflow run \
  epi2me-labs/wf-human-variation \
  -r v2.8.1 \
  --bam data/raw/wf_demo/wf-human-variation-demo/demo.bam \
  --ref data/raw/wf_demo/wf-human-variation-demo/demo.fasta \
  --bed data/raw/wf_demo/wf-human-variation-demo/demo.bed \
  --sample_name DEMO \
  --snp \
  --annotation true \
  --out_dir results/05_nextflow_demo \
  -profile standard \
  -resume
```

34. Output Nextflow cần xem

Tên file có thể phụ thuộc release. Với release v2.8.1 và `--sample_name DEMO` , các output thường dùng dùng tiền tố mẫu DEMO ; xác nhận tên thực tế trong log và thư mục output:

```
results/05_nextflow_demo/
├── DEMO.wf-human-alignment-report.html
├── DEMO.wf-human-snp-report.html
├── DEMO.wf_snp.vcf.gz
├── DEMO.wf_snp.vcf.gz.tbi
├── DEMO.wf_snp_clinvar.vcf.gz
└── DEMO.stats.json
```

35. Manual workflow và Nextflow workflow


Quy trình thủ công	wf-human-variation
Học rõ từng command và file trung gian	Tự orchestration các process
Dễ thay đổi từng bước để học	Cấu hình tập trung bằng parameters
Học viên tự quản lý log/version	Workflow ghi execution metadata
Tự chạy Clair3, SnpEff, ClinVar	Nhánh SNP tích hợp calling và annotation
Phù hợp để hiểu nguyên lý	Phù hợp để chạy pipeline chuẩn hóa

Hai output không bắt buộc giống tuyệt đối nếu khác:

- version Clair3/model;
- database SnpEff/ClinVar;
- filters;
- BED;
- normalization;
- workflow release.

TỔNG KẾT TOÀN KHÓA

36. Toàn cảnh quy trình phân tích



37. Checklist trước khi chia sẻ kết quả

- ☐ Đúng sample, assembly, reference và quy ước tên contig.
 - ☐ Đã xem QC, coverage và giới hạn của vùng phân tích.
 - ☐ Clair3 model phù hợp dữ liệu và đã xác định đúng VCF cuối.
 - ☐ Variant đã được chuẩn hóa, lọc theo tiêu chí rõ ràng và kiểm tra khi cần.
 - ☐ Benchmark dùng truth set và confident regions phù hợp.
 - ☐ ClinVar ghép theo exact allele và có ghi phiên bản/release.
 - ☐ Báo cáo phân biệt dự đoán tin sinh học với ý nghĩa lâm sàng.
 - ☐ Workflow, công cụ, tham số, logs và giới hạn (nếu có)
-

Tài liệu tham khảo

1. SnpEff documentation: <https://pcingola.github.io/SnpEff/> (<https://pcingola.github.io/SnpEff/>)
 2. SnpEff ANN field: <https://pcingola.github.io/SnpEff/snpeff/inputoutput/>
(<https://pcingola.github.io/SnpEff/snpeff/inputoutput/>)
 3. SnpEff human databases: <https://pcingola.github.io/SnpEff/snpeff/download/>
(<https://pcingola.github.io/SnpEff/snpeff/download/>)
 4. SnpSift extractFields: <https://pcingola.github.io/SnpEff/snpsift/extractfields/>
(<https://pcingola.github.io/SnpEff/snpsift/extractfields/>)
 5. bcftools manual: <https://samtools.github.io/bcftools/bcftools.html> (<https://samtools.github.io/bcftools/bcftools.html>)
 6. ClinVar VCF GRCh38: https://ftp.ncbi.nlm.nih.gov/pub/clinvar/vcf_GRCh38/
(https://ftp.ncbi.nlm.nih.gov/pub/clinvar/vcf_GRCh38/)
 7. ClinVar review status: https://www.ncbi.nlm.nih.gov/clinvar/docs/review_status/
(https://www.ncbi.nlm.nih.gov/clinvar/docs/review_status/)
 8. ClinVar data interpretation: <https://www.ncbi.nlm.nih.gov/clinvar/docs/interpretation/>
(<https://www.ncbi.nlm.nih.gov/clinvar/docs/interpretation/>)
 9. EPI2ME wf-human-variation: <https://github.com/epi2me-labs/wf-human-variation> (<https://github.com/epi2me-labs/wf-human-variation>)
 10. Workflow documentation: <https://labs.epi2me.io/wfindex/> (<https://labs.epi2me.io/wfindex/>)
 11. Nextflow documentation: <https://www.nextflow.io/docs/latest/> (<https://www.nextflow.io/docs/latest/>)
-

Một số nguồn tham khảo khác

1. Galaxy Training: <https://training.galaxyproject.org/> (<https://training.galaxyproject.org/>)
 2. Coursera: <https://www.coursera.org/search?query=bioinformatics> (<https://www.coursera.org/search?query=bioinformatics>)
 3. edX: <https://www.edx.org/learn/bioinformatics> (<https://www.edx.org/learn/bioinformatics>)
-

🎓 LỜI CHÀO CUỐI KHÓA HỌC

💙 Cảm ơn các em!

Vậy là chúng ta đã đi đến **buổi học cuối cùng** của khóa học.

Trong suốt hành trình vừa qua, chúng ta đã cùng nhau đi từ những bước đầu tiên với dữ liệu **Oxford Nanopore** 🧬 đến việc xây dựng một quy trình phân tích bioinformatics hoàn chỉnh:

POD5 → FASTQ → QC → Alignment → Variant Calling → Annotation → Interpretation 🧪

🌱 Điều quan trọng nhất

Hy vọng sau khóa học này, các em không chỉ biết **chạy một vài command**, mà còn hiểu được cách:

🔍 **Đặt câu hỏi**

📊 **Kiểm tra và đánh giá dữ liệu**

🧬 **Hiểu ý nghĩa của từng bước phân tích**

⚙️ **Xử lý khi workflow gặp lỗi**

📖 **Tự tìm hiểu khi gặp một bài toán mới**

💡 **Bioinformatics không chỉ là chạy pipeline — mà là hiểu dữ liệu và biết mình đang làm gì.**

🚀 Hành trình vẫn tiếp tục...

Sau khóa học, chắc chắn sẽ còn rất nhiều điều mới để khám phá:

Điều quan trọng là hãy tiếp tục:

Learn → Practice → Question → Explore → Improve ✨

❤️ Cảm ơn các em đã đồng hành!

Cảm ơn các em đã dành thời gian tham gia khóa học, đặt câu hỏi, thực hành và cùng nhau giải quyết những vấn đề trong quá trình học.

Hy vọng những kiến thức và kỹ năng trong 6 buổi học này sẽ trở thành **một nền tảng để các em tiếp tục khám phá thế giới Bioinformatics**. 🌍 🧬

💙 **Chúc các em thật nhiều thành công trên hành trình phía trước!**